



دانشگاه صنعتی امیرکبیر
(پلی‌تکنیک تهران)
دانشکده مهندسی کامپیووتر

گزارش پژوهه کارشناسی

سامانه پیش‌بینی ارزهای دیجیتال با استفاده از یادگیری عمیق

نگارش
حسین بهشتی‌فرد

استاد راهنما
محمد‌مهدی عبادزاده

۱۴۰۱ مهر



به نام خدا

تاریخ: مهر ۱۴۰۱

تعهدنامه اصالت اثر

دانشگاه صنعتی امیرکبیر
(پلی‌تکنیک تهران)

اینجانب حسین بهشتی‌فرد متعدد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی استاد دانشگاه امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مأخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است.

در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطلب با ذکر مأخذ بلامانع است.

حسین بهشتی‌فرد

امضا

تقدیم به خانواده و دوستان دلسوژم که همواره در سختی‌ها پشتیبانی محکم و مطمئن برایم بوده‌اند.

سپاس‌گزاری

از استاد محترم؛ جناب دکتر محمدمهری عبادزاده و تمامی عزیزانی که با صبر و حوصله،
از هیچ کمکی در مسیر انجام این پروژه و نوشتمن این پایان‌نامه از من دریغ ننمودند، کمال
تشکر و قدردانی را دارم.

حسین بهشتی‌فرد
۱۴۰۱ مهر

چکیده

امروزه، تحلیل و پیش‌بینی بازارهای مالی از جمله بازار رمざرزها که در سال‌های اخیر رشد قابل توجهی داشته است، از موضوعات داغ و مورد توجه می‌باشد. تحلیل بازار اغلب با استفاده از روش‌های تکنیکی و بنیادین صورت می‌گیرد. اما در دهه‌های اخیر، با پیشرفت هوش مصنوعی، محققان همواره به‌دبیال طراحی الگوریتم و مدل‌های نوین جهت پیش‌بینی بازار بوده‌اند. در سال‌های اخیر نیز به‌دبیال پیشرفت کارت‌های گرافیکی، شبکه‌های عصبی و تکنیک‌های یادگیری عمیق به‌شدت مورد توجه قرار گرفته‌اند.

در این پژوهه از دو مدل پرطرفدار حافظه کوتاه مدت ماندگار و واحد بازگشتی دروازه‌ای جهت پیش‌بینی قیمت رمزارزها استفاده می‌کنیم. این مدل‌ها از دسته مدل‌های بازگشتی می‌باشند؛ که در پیش‌بینی داده‌های زمانی و ترتیبی عملکرد خوبی از خود نشان داده‌اند. پس از آن، با استفاده از روش‌های تجمعی، مدل‌ها را ترکیب و یک مدل جدید ارائه می‌دهیم. پس از یافتن فراپارامترهای مناسب و انتخاب معماری، مدل‌های خود را بر روی داده‌های سه رمزارز بیت‌کوین، اتریوم و ریپل آزمایش و ارزیابی می‌کنیم. در آخر، یک سامانه تحت وب جهت پیش‌بینی قیمت رمزارزها با مدل‌های ذکر شده، پیاده‌سازی می‌کنیم.

واژه‌های کلیدی:

یادگیری عمیق – شبکه‌های بازگشتی – مدل حافظه کوتاه مدت ماندگار – واحد بازگشتی دروازه‌ای –
مدل ترکیبی – پیش‌بینی قیمت رمزارزها

عنوان	
صفحه	
فهرست مطالب	
فصل ۱ مقدمه ۷	
فصل ۲ مفاهیم بازار ۱۱	
۱۲	- نمودارهای قیمت.....
۱۲	- دوره زمانی..... ۱-۱-۲
۱۲	- نمایش نمودارهای قیمتی..... ۲-۱-۲
۱۵	- تحلیل قیمت در بازارهای مالی..... ۲-۲
۱۵	- تحلیل بنیادین..... ۱-۲-۲
۱۶	- تحلیل تکنیکی..... ۲-۲-۲
۲۱	- مشکلات بازار رمزارزها..... ۳-۲
فصل ۳ شبکه‌های عصبی ۲۲	
۲۳	- پیدایش شبکه‌های عصبی..... ۱-۳
۲۵	- اجزا شبکه‌های عصبی..... ۲-۳
۲۷	- مراحل شبکه‌های عصبی..... ۳-۳
۲۸	- یادگیری عمیق..... ۴-۳
۲۹	- شبکه‌های عصبی بازگشتی..... ۵-۳
۳۲	- مدل حافظه کوتاه مدت ماندگار..... ۱-۵-۳
۳۵	- مدل واحد بازگشتی دروازه‌ای..... ۱-۵-۳
فصل ۴ کارهای پیشین ۳۸	
۳۹	- مقدمه..... ۱-۴
۳۹	- کارهای پیشین انجام شده در حوزه یادگیری عمیق..... ۲-۴
۴۱	- خلاصه..... ۳-۴
فصل ۵ طراحی و پیاده‌سازی ۴۲	
۴۳	- مقدمه..... ۱-۵
۴۳	- کتابخانه‌ها و ابزارها..... ۲-۵
۴۴	- کتابخانه yfinance..... ۱-۲-۵
۴۴	- کتابخانه تنسورفلو..... ۱-۲-۵
۴۵	- رابط برنامه‌نویسی کراس..... ۳-۲-۵
۴۵	- Streamlit..... ۴-۲-۵
۴۶	- چارچوب..... ۳-۵
دریافت داده‌ها..... ۳-۵	

۵۱	۴-۵- پیش‌پردازش و آماده‌سازی داده‌ها.....
۵۱	۱-۴-۵- تقسیم داده‌ها.....
۵۳	۲-۴-۵- نرمال‌سازی.....
۵۳	۳-۴-۵- آماده‌سازی داده‌ها.....
۵۵	۴-۵- طراحی و پیاده‌سازی مدل‌ها.....
۵۵	۱-۵-۵- مدل حافظه کوتاه مدت ماندگار.....
۶۰	۲-۵-۵- مدل واحد بازگشتی دروازه‌ای.....
۶۲	۳-۵-۵- مدل ترکیبی.....
۶۴	۴-۵-۵- فرآیند آموزش مدل‌ها.....
۶۵	۵-۵-۵- یافتن فراپارامترهای مناسب.....
۶۹	۶-۵-۵- نحوه پیش‌بینی قیمت روزهای آتی.....
۶۹	۶-۵- سامانه پیش‌بینی قیمت رمزارزها.....
۷۲	فصل ۶ ارزیابی و بورسی عملکرد.....
۸۱	فصل ۷ جمع‌بندی.....
۸۲	۱-۷- مقدمه.....
۸۲	۲-۷- نتایج.....
۸۲	۳-۷- کارهای آینده.....
۸۴	منابع.....

صفحه	فهرست شکل‌ها	شکل
		۱۳
	شکل ۱ - نمایش نمودار خطی داده‌های قیمتی رمزارز بیت‌کوین	شکل ۲ - شمع قیمتی
۱۴		۱۴
	شکل ۳ - نمایش نمودار شمعی داده‌های قیمتی رمزارز بیت‌کوین	شکل ۴ - سطوح حمایتی و مقاومتی
۱۷		۱۷
	شکل ۵ - چند نمونه از الگوهای قیمتی	شکل ۶ - اجزای شبکه عصبی بیولوژیکی
۲۰		۲۰
	شکل ۷ - مدل تک پرسپترون	شکل ۸ - ساختار شبکه عصبی مصنوعی با دو لایه پنهان
۲۴		۲۶
	شکل ۹ - ساختار سلول‌های شبکه بازگشتی ساده	شکل ۱۰ - نمایش بازشده شبکه‌های بازگشتی
۲۹		۳۰
	شکل ۱۱ - فاصله زیاد گام‌های زمانی اطلاعات مورد نیاز	شکل ۱۲ - ساختار سلول‌های شبکه حافظه کوتاه مدت ماندگار
۳۱		۳۲
	شکل ۱۳ - معنای علائم استفاده شده در شبکه	شکل ۱۴ - نمایش حالت سلول در شبکه حافظه کوتاه مدت ماندگار
۳۳		۳۳
	شکل ۱۵ - دروازه فراموشی در شبکه حافظه کوتاه مدت ماندگار	شکل ۱۶ - دروازه ورودی در شبکه حافظه کوتاه مدت ماندگار
۳۴		۳۴
	شکل ۱۷ - اعمال تغییرات در حالت سلول شبکه حافظه کوتاه مدت ماندگار	شکل ۱۸ - دروازه خروجی در شبکه حافظه کوتاه مدت ماندگار
۳۵		۳۵
	شکل ۱۹ - ساختار سلول واحد بازگشتی دروازه‌ای	شکل ۲۰ - نماد تنسورفلو
۴۴		۴۴
	شکل ۲۱ - نماد کراس	شکل ۲۲ - نماد streamlit
۴۵		۴۵
	شکل ۲۳ - نمودارهای lag در دوره‌های زمانی متفاوت رمزارز بیت‌کوین	شکل ۲۴ - داده‌های روزانه بیت‌کوین، دریافت شده از طریق رابطه‌ای برنامه‌نویسی yfinance
۴۷		۴۸
	شکل ۲۵ - داده‌های روزانه اتریوم، دریافت شده از طریق رابطه‌ای برنامه‌نویسی yfinance	شکل ۲۶ - داده‌های روزانه ریپل، دریافت شده از طریق رابطه‌ای برنامه‌نویسی yfinance
۴۹		۴۹
	شکل ۲۷ - نمودار قیمت بیت‌کوین پس از تقسیم داده‌ها	شکل ۲۸ - نمودار قیمت اتریوم پس از تقسیم داده‌ها
۵۱		۵۲
	شکل ۲۹ - نمایش نمودار قیمت ریپل پس از تقسیم داده‌ها	شکل ۳۰ - معماری شبکه با سه لایه حافظه کوتاه مدت ماندگار
۵۲		۵۷

..... شکل ۳۱ - ساختار سلول حافظه کوتاه مدت ماندگار با دو واحد پنهان	۵۸
..... شکل ۳۲ - ترکیب مدل‌ها با روش تجمعی Stacking	۶۳
..... شکل ۳۳ - بخش انتخاب رمزارز، مدل و بازه پیش‌بینی در سامانه	۷۰
..... شکل ۳۴ - نمایش داده‌های عددی در سامانه	۷۰
..... شکل ۳۵ - نمایش نمودار قیمت در سامانه	۷۱
..... شکل ۳۶ - نمایش نتایج پیش‌بینی‌ها در سامانه	۷۱
..... شکل ۳۷ - نمودار خط‌نمودار حافظه کوتاه مدت ماندگار در فرآیند آموزش	۷۳
..... شکل ۳۸ - نمودار خط‌نمودار واحد بازگشتی دروازه‌ای در فرآیند آموزش	۷۳
..... شکل ۳۹ - نمودار خط‌نمودار ترکیبی در فرآیند آموزش	۷۴
..... شکل ۴۰ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز بیت‌کوین توسط مدل حافظه کوتاه مدت ماندگار	۷۴
..... شکل ۴۱ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز بیت‌کوین توسط مدل واحد بازگشتی دروازه‌ای	۷۵
..... شکل ۴۲ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز بیت‌کوین توسط مدل ترکیبی	۷۵
..... شکل ۴۳ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز اتریوم توسط مدل حافظه کوتاه مدت ماندگار	۷۶
..... شکل ۴۴ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز اتریوم توسط مدل واحد بازگشتی دروازه‌ای	۷۶
..... شکل ۴۵ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز اتریوم توسط مدل ترکیبی	۷۷
..... شکل ۴۶ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز ریپل توسط مدل حافظه کوتاه مدت ماندگار	۷۷
..... شکل ۴۷ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز ریپل توسط مدل واحد بازگشتی دروازه‌ای	۷۸
..... شکل ۴۸ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز ریپل توسط مدل ترکیبی	۷۸

جدول جداول فهرست صفحه

جدول ۱ - خطای پیش‌بینی مدل حافظه کوتاه مدت ماندگار با ساختارهای متفاوت.....	۶۶
جدول ۲ - خطای پیش‌بینی مدل واحد بازگشتی دروازه‌ای با ساختارهای متفاوت.....	۶۷
جدول ۳ - خطای پیش‌بینی مدل‌های ارائه شده بر روی رمزارز بیت‌کوین.....	۷۹
جدول ۴ - خطای پیش‌بینی مدل‌های ارائه شده بر روی رمزارز اتریوم.....	۷۹
جدول ۵ - خطای پیش‌بینی مدل‌های ارائه شده بر روی رمزارز ریپل.....	۷۹

فصل ۱

مقدمه

در ابتدا نیاز است بگوییم که بازارهای مالی به علت نیاز مردم و شرکت‌ها پدید آمده‌اند و وجود آن‌ها نقش مهمی در چرخه‌ی اقتصاد کشورها دارد. از این رو همواره پیداکردن فرصت‌های مناسب و انجام معاملات سود ده برای معامله‌گران و سرمایه‌گذاران امری مهم و حیاتی است. رفتار و نوسان‌های قیمتی برخلاف تصور عموم، به طور تصادفی نیست و پشت این جابه‌جایی‌های قیمتی دلیل‌های علمی وجود دارد. دو متغیر عرضه و تقاضا، علت اصلی این تغییرات قیمت هستند. به‌این معنا که اگر تقاضا زیاد باشد، قیمت افزایش و اگر عرضه زیاد باشد، قیمت کاهش می‌یابد و بلعکس. به‌طور کلی پیش‌بینی قیمت به دلیل ماهیت داده‌های مالی چالش برانگیز می‌باشد. علاوه بر این، تعامل پیچیده عوامل سیاسی و اقتصادی، پیش‌بینی بازار را نیز دشوارتر می‌کند.

با پیشرفت تکنولوژی و ظهور اینترنت، رفته رفته بازارهای مالی از شکل سنتی خود خارج شدند و امکان انجام معاملات از طریق اینترنت فراهم شد. این امر سبب شد که اطلاعات و داده‌های مورد نیاز مانند قیمت، تعداد معاملات و اخبار پیرامون سهم‌ها در دسترس قرار بگیرند و در نتیجه‌ی آن، نمودارهای قیمتی و شاخص‌های تکنیکی پدید آمدند. در سال‌های اخیر، پدیده شبکه زنجیره‌ای بلوکهای^۱ و رمزارزها^۲ به شدت توجه معامله‌گران و سرمایه‌داران را جذب خود کرده و به‌دلیل آن، پیش‌بینی رفتار قیمتی این ارزها از اهمیت بالایی برخوردار شده‌است. از این رو، در پروژه‌های تحقیقاتی و صنعتی روش‌های متعددی برای پیش‌بینی رفتار قیمتی مورد استفاده قرار گرفته است.

همانطور که گفته شد، تغییرات قیمتی در بازارهای مالی بصورت تصادفی نیست و دلیل‌های علمی در پشت خود دارد. در علم اقتصاد، تحلیل قیمتی به دو دسته‌ی اصلی تحلیل تکنیکی^۳ و تحلیل بنیادین^۴ تقسیم می‌شوند. تحلیل بنیادین شامل بررسی مجموعه‌ای از موارد پیرامون یک ارز مبنی بر میزان سود ده بودن و آینده آن در برابر رقبا می‌باشد. در حالی که تحلیل تکنیکی با استفاده از مطالعه رفتار و حرکات قیمت و حجم ارز در گذشته و پیش‌بینی قیمت و روند آینده آن صورت می‌پذیرد.

¹ Blockchain

² Cryptocurrency

³ Technical Analysis

⁴ Fundamental Analysis

در دهه‌های اخیر، توسعه هوش مصنوعی و مدل‌های یادگیری ماشین^۵ کمک شایانی به این حوزه کرده است. با استفاده از الگوریتم‌های پیش‌بینی یادگیری ماشین و با داشتن داده‌ها و گذشته‌ی قیمتی رمزارزها، می‌توان فرآیند یادگیری را انجام داد و درنتیجه، رفتار قیمتی رمزارز را در آینده پیش‌بینی نمود. شبکه‌های عصبی مصنوعی^۶ دسته‌ای از مدل‌های یادگیری ماشین می‌باشند، که مطابق با مغز انسان مدل شده‌اند. همانطور که سلول‌های عصبی سیستم عصبی ما می‌توانند از داده‌های گذشته، تجربه کسب کنند، به همین صورت شبکه‌های عصبی مصنوعی نیز قادر به یادگیری از داده‌ها و ارائه پاسخ در قالب پیش‌بینی‌ها و طبقه‌بندی‌ها هستند.

الگوریتم‌های یادگیری عمیق^۷ نیز در سال‌های اخیر بسیار مورد توجه قرار گرفته‌اند. این الگوریتم‌ها با استفاده از شبکه‌های عصبی با تعداد لایه‌های پنهان^۸ و تعداد نورون بیشتر، سعی در حل مسائل پیچیده‌تر دارند. شبکه‌های عصبی بازگشتی^۹، دسته‌ای از الگوریتم‌های یادگیری عمیق‌اند که در مسائل وابسته به داده‌های زمانی^{۱۰} و ترتیبی^{۱۱}، مانند پیش‌بینی قیمت ارزها بر اساس قیمت لحظه‌ای، کاربرد دارند. در این شبکه‌ها، اتصالات بازخورد دهنده میان گره‌ها وجود دارد، که درنتیجه باعث می‌شود شبکه به‌گونه‌ای دارای حافظه باشد و اطلاعات مورد نیاز گذشته را در خود نگه داد.

در این پژوهه، هدف طراحی و پیاده‌سازی یک سامانه تحت وب به‌منظور پیش‌بینی قیمت رمزارزها با استفاده از الگوریتم‌های یادگیری عمیق و با تمرکز بر شبکه‌های عصبی بازگشتی می‌باشد. همانطور، در این پژوهه قصد داریم که الگوریتم‌های خود را بر روی سه رمزارز شناخته شده بیت‌کوین^{۱۲}، اتریم^{۱۳} و ریپل^{۱۴} آزمایش و ارزیابی کنیم.

⁵ Machine Learning

⁶ Artificial Neural Network (ANN)

⁷ Deep Learning

⁸ Hidden Layers

⁹ Recurrent Neural Network (RNN)

¹⁰ Temporal

¹¹ Sequential

¹² Bitcoin

در این گزارش در ابتدا به توضیح تعدادی از مفاهیم بازار می‌پردازیم. علم به یک سری از مفاهیم پایه بازار جهت طراحی و ارزیابی بهتر مدل‌ها ضروری است. سپس به بررسی شبکه‌های عصبی و شبکه‌های عصبی بازگشتی می‌پردازیم. پس از آن، تعدادی از تحقیقات پیشین انجام شده در حوزه پیش‌بینی قیمت را بررسی می‌کنیم. در آخر نیز به طراحی و پیاده سازی مدل‌ها و ارزیابی آن‌ها می‌پردازیم.

¹³ Ethereum

¹⁴ Ripple

فصل ۲

مفاهیم بازار

۱-۲- نمودارهای قیمت

همانطور که در شکل ۱ و ۳ مشاهده می‌کنیم، محور عمودی نشان دهنده قیمت می‌باشد و محور افقی زمان را نشان می‌دهد. در نتیجه، نمودار سهام یا رمزارز، روند تغییرات قیمت یا ارزش را نسبت به زمان نشان می‌دهد. نیاز به ذکر است که در بازارهای مالی ارز یا سهام‌ها بصورت جفت ارز بررسی می‌شوند. یعنی نسبت یک ارز یا سهام را به نسبت یک ارز یا سهام یا واحد پولی دیگر می‌سنجیم.

۱-۲-۱- دوره زمانی^{۱۵}

در بازارهای مالی، می‌توان نمودارهای قیمت را در دوره‌های زمانی مختلف(دقیقه، ساعت، روزانه، هفتگی، ماهیانه و ...) بررسی و تحلیل نمود. بسته به هدف و استراتژی معاملاتی، تحلیل‌گران از دوره‌های زمانی متفاوتی استفاده می‌کنند. دوره‌های زمانی کوتاه‌تر، اطلاعات دقیق‌تری به ما نمایش می‌دهند؛ که معمولاً جهت نوسان‌گیری و یا پیدا کردن نقاط دقیق واکنشی مورد استفاده قرار می‌گیرند. از طرف دیگر، دوره‌های زمانی بلندتر، درک بهتری از روند کلی بازار می‌دهند و برای تحلیل طولانی مدت مناسب‌تر هستند.

۱-۲-۲- نمایش نمودارهای قیمتی

نمودارهای قیمتی به گونه‌های مختلفی نمایش داده می‌شود. اصلی‌ترین طبقه بندی نمودارها، نمودار خطی، نمودار میله‌ای، نمودار شمعی^{۱۶}، نمودار هیکن آشی^{۱۷} و نمودار تو خالی می‌باشند. در این میان، نمودار خطی و نمودار شمعی معمولاً نزد معامله‌گران محبوب‌تر می‌باشند.

¹⁵ Time Frame

¹⁶ Candlestick

¹⁷ Hikin-Ashi

• نمودار خطی

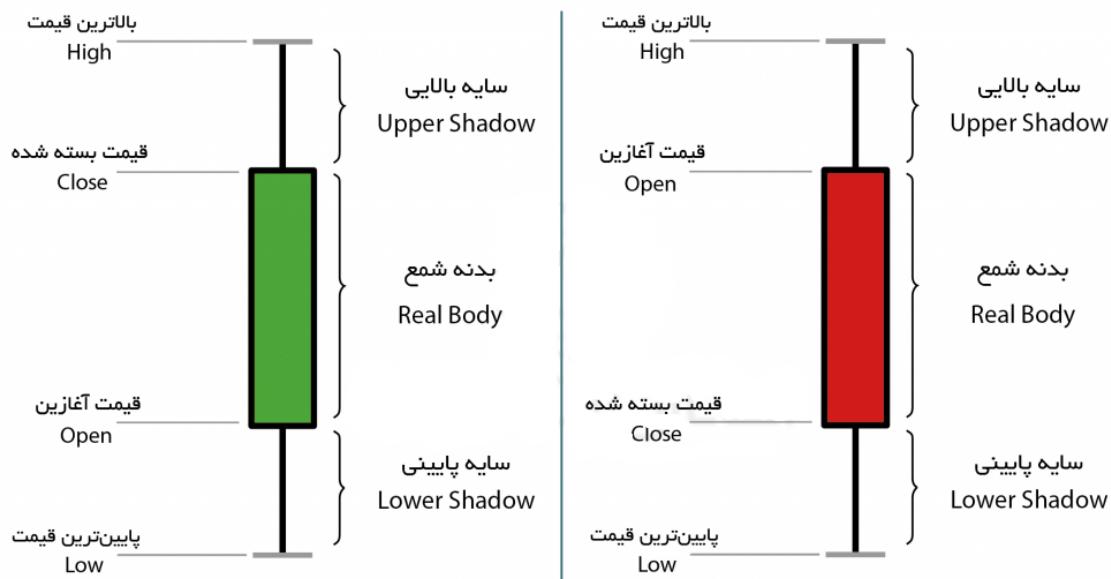
نمودار خطی، ابتدایی ترین و ساده‌ترین نوع از انواع نمودارهای قیمت می‌باشد. این نمودار با اتصال نقاطی که قیمت پایانی سهم یا ارز را نشان می‌دهند، به دست می‌آید. این نمودار برای افرادی که قصد ارائه گزارش عمومی از بازار و حرکات قیمتی گذشته را دارند، بسیار ساده و واضح است.



شکل ۱ - نمایش نمودار خطی داده‌های قیمتی رمزارز بیت‌کوین

• نمودار شمعی

نمودار شمعی به نموداری گفته می‌شود که شکل و شمايل آن مانند یک شمع است. این نمودار درک بهتری نسبت به رفتار قیمتی سهم یا ارز می‌دهد، زیرا در آن قیمت باز و بسته شدن ارز و همچنین بالاترین و پایین‌ترین قیمت در دوره‌زمانی مربوطه، مشخص است. بنابراین، رفتار قیمت و بازار بهتر می‌تواند مورد تحلیل قرار بگیرد.



شکل ۲ - شمع قیمتی

نیاز به ذکر است که هر شمع نمایانگر اطلاعات قیمت در دوره زمانی مورد استفاده است. بطور مثال، اگر دوره زمانی مورد تحلیل روزانه باشد، به ازای هر روز یک شمع خواهیم داشت.



شکل ۳ - نمایش نمودار شمعی داده‌های قیمتی رمزارز بیت‌کوین

۲-۲- تحلیل قیمت در بازارهای مالی

در ابتدا پیش از اینکه وارد بحث اصلی شویم، نیاز است که با عوامل موثر بر جابه‌جایی قیمت و چگونگی استفاده از علوم اقتصاد جهت طراحی الگوریتم‌های پیش‌بینی، آشنا شویم.

در بازارهای مالی به مجموعه اقداماتی که سبب می‌شود بتوان آینده‌ی قیمتی یک ارز یا سهم را پیش‌بینی کرد، تحلیل قیمتی گفته می‌شود.

همانطور که گفته شد، تحلیل قیمتی به دو دسته‌ی اصلی تحلیل تکنیکی و تحلیل بنیادی تقسیم می‌شوند.

۲-۲-۱- تحلیل بنیادین

تحلیل بنیادین یک شرکت شامل تحلیل گزارش‌های مالی و سلامت مالی شرکت، مدیریت و امتیازات رقابتی، رقبا و بازارهای مربوطه است. هنگامی که این تحلیل در بازارهای آتی^{۱۸} و فارکس^{۱۹} به کار می‌رود، تمرکز اصلی بر شرایط اقتصادی، نرخ بهره، تولید، سودآوری و مدیریت است. این تحلیل در بازار رمざزانها اغلب شامل بررسی کد، توضیحات، برنامه‌ریزی‌ها و اهداف آینده‌ی ارائه شده توسط توسعه دهندگان و ذینفعان می‌باشد.

در تحلیل بنیادین اساس پیش‌بینی بر مبنای واقعی و رخدادهای واقعی پایه‌گذاری شده است. پایه نظر تحلیل گران بنیادی این است که تمام تغییرات قیمتی حتماً یک علت اقتصادی بنیادی دارد. این نوع از تحلیل نسبت به تحلیل تکنیکی بسیار زمان‌گیرتر است و معمولاً همراه با جمع‌آوری اطلاعات از منابع مختلف ممکن می‌گردد.

به‌طورکلی، تحلیل تمام جوانب و عوامل موثر بر یک پروژه یا شرکت به‌طوری که بتوان ارزش ذاتی و پتانسیل‌های بالقوه آن را تشخیص داد، به عنوان تعریف تحلیل بنیادین شناخته می‌شود. [۱]

¹⁸ Futures

¹⁹ Forex

۲-۲-۲- تحلیل تکنیکی

تحلیل تکنیکی با استفاده از مطالعه رفتار و حرکات قیمت و حجم ارز در گذشته و پیش‌بینی قیمت و روند آینده آن صورت می‌پذیرد. بسیاری از اقتصاددانان معتقدند که گذشته‌ی یک سهم برای پیش‌بینی آینده آن کافی است، زیرا تاریخ دوباره تکرار می‌شود. این تحلیل به دو صورت تحلیل آماری که با استفاده از نسبت‌های آماری و شاخص‌ها^{۲۰} انجام می‌گیرد و تحلیل گرافیکی که به وسیله‌ی ابزارهای گرافیکی، انجام می‌شود.

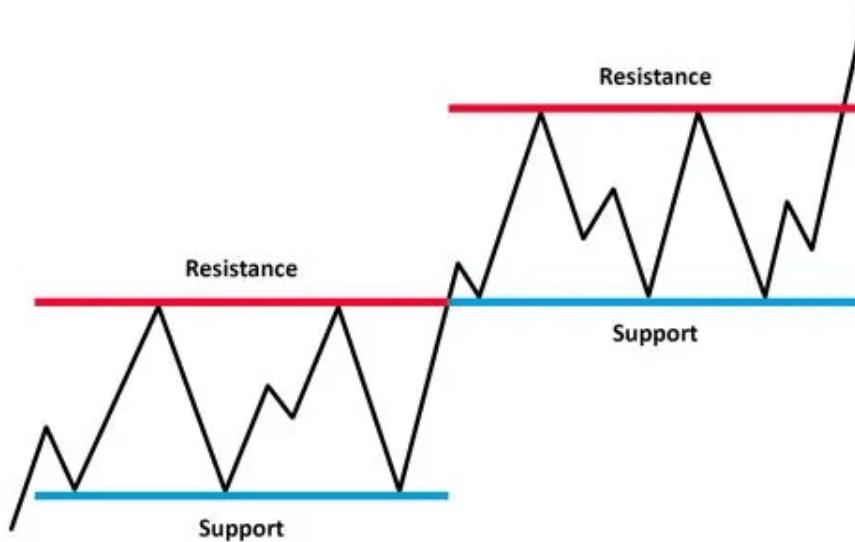
۱. حمایت و مقاومت

دو اصطلاح در تحلیل تکنیکی می‌باشند، که به سطوحی که فشار خرید از سوی خریداران و یا فروش از سوی فروشنده‌گان زیاد باشد، اشاره دارد. این سطوح می‌توانند بر اساس درصدهای فیبوناتچی، الگوهای قیمتی، خطوط روند و سقف و کف‌های قیمتی تعیین شوند.

سقف قیمتی یعنی در دوره‌های قبلی وقتی قیمت به آن نقطه رسیده، موفق نشده که بالاتر رود و به پایین می‌کرده، در نتیجه متوجه می‌شویم که در این نقطه یک مقاومت وجود دارد که ناشی از فشار فروشنده‌گان است. اما اگر قیمت از این نقطه بتواند عبور کند به اصلاح آن را شکسته و ممکن است به بالا جهش کند. بعد از آن این مقاومت به صورت حمایت عمل می‌کند.

به طور مقابل کف قیمتی، نشان‌دهنده فشار خریداران است و به سطوحی اشاره دارد که در گذشته قیمت چندبار از آن سطح برگشته است. اگر این سطح شکسته شود، یعنی فشار فروش بیشتر از خرید بوده است و سپس این سطح به مقاومت تبدیل خواهد شد. [۲]

²⁰ Indicator



شکل ۴ - سطوح حمایتی و مقاومتی

۲. شاخص‌های تکنیکی

محاسبات ریاضیاتی‌ای بر اساس تاریخچه قیمت و حجم داده‌ها هستند که هدف آن‌ها پیش‌بینی جهت بازار مالی می‌باشد. امروزه بیش از ۲۰۰ شاخص مختلف وجود دارد که به‌طورکلی در سه دسته‌ی شاخص‌های مربوط به حجم، مربوط به روند و شاخص‌های نوسان‌گر^{۲۱} قرار می‌گیرند.

• شاخص‌های مربوط به حجم

دسته‌ای از شاخص‌ها هستند که حجم معاملات را مورد بررسی و ارزیابی قرار می‌دهند. حجم معاملات در دوره‌های زمانی مشخص، دارای معانی مهمی برای تحلیل‌گران می‌باشد، که در تصمیم‌گیری آن‌ها تأثیرگذار خواهد بود.

• شاخص‌های مربوط به روند

²¹ Oscillator

این شاخص‌ها از نوع تأخیری هستند و معمولاً بر روی نمودار قیمت ایجاد می‌شوند و عموماً با میانگین‌گیری از نمودار قیمت، اطلاعاتی را برای تحلیل و تصمیم‌گیری در اختیار تحلیل‌گران قرار می‌دهند.

در اینجا دو نمونه از شاخص‌های پرطرفدار مربوط به روند را بررسی می‌کنیم.

- شاخص میانگین متحرک ساده

میانگین متحرک می‌تواند در بازه‌های مختلف بررسی شود. مثلاً در بازه‌ی ۱۰۰ روز، یعنی نمودار در هر نقطه میانگین قیمتی در ۱۰۰ روز گذشته از آن زمان را نشان می‌دهد.

$$SMA_n = \frac{C_1 + C_2 + \dots + C_n}{n}$$

که n نشان‌دهنده‌ی بازه زمانی و C_n قیمت پایانی در n روز می‌باشد.

- شاخص میانگین متحرک نمایی

مانند میانگین متحرک ساده است اما دارای ضریب می‌باشد.

$$\text{Weighting Multiplier}_n = \frac{2}{n+1}$$

$$EMA_n = ((C_t - EMA_{n-1}) * \text{Weighting Multiplier}_n) + EMA_{n-1}$$

که در این فرمول، C_t قیمت پایانی می‌باشد.

• شاخص‌های نوسان‌گر

همانطور که از نام آن‌ها پیداست، نوسان‌گر هستند و در محدوده خاصی حرکت می‌کنند. نوسان‌گرها توانایی بررسی قدرت روند را دارند و وجود ضعف در روند تا حدودی در نوسان‌گرها قابل مشاهده است. از دیگر ویژگی نوسان‌گرها بررسی هیجانات بازار می‌باشد. زمانی که خرد جمعی واکنشی به قیمت‌ها نشان دهد، نوسان‌گرها نیز به این موضوع واکنش نشان می‌دهند.

دو مورد از معروف‌ترین شاخص‌های این دسته شاخص مکدی و شاخص قدرت نسبی می‌باشد.

- مکدی^{۲۲}:

شاخص مکدی به بررسی قدرت و شتاب روند می‌پردازد. این شاخص شامل دو میانگین متحرک با نامهای خط مکدی و خط سیگنال است که تقاطع این دو خط در شرایطی خاص سیگنال‌هایی برای تحلیل‌گران صادر می‌کند، که می‌تواند مبنای تصمیم‌گیری قرار گیرد. در واقع شاخص مکدی با محاسبه تفاصل دو میانگین متحرک (معمولاً میانگین دوره زمانی ۲۶ و ۱۲) یک نوسان‌گر ایجاد می‌کند، که می‌تواند ضعف و یا قدرت روند را نشان دهد. خط سیگنال نیز معمولاً بر اساس دوره زمانی ۹ ساخته می‌شود.

- شاخص قدرت نسبی^{۲۳}:

این شاخص قدرت روند را به خوبی حدس می‌زند و میانگین افزایش قیمت‌ها را در یک بازه‌ی زمانی مشخص محاسبه نموده و آن را تقسیم بر میانگین کاهش قیمت‌ها در همان بازه می‌کند و سپس حاصل را به صورت شاخص ریاضی که بین ۰ تا ۱۰۰ درصد قابل نوسان است، ارائه می‌دهد. فرمول این شاخص به شکل زیر است:

$$RSI = 100 - \frac{100}{1 + RS}$$

²² MACD

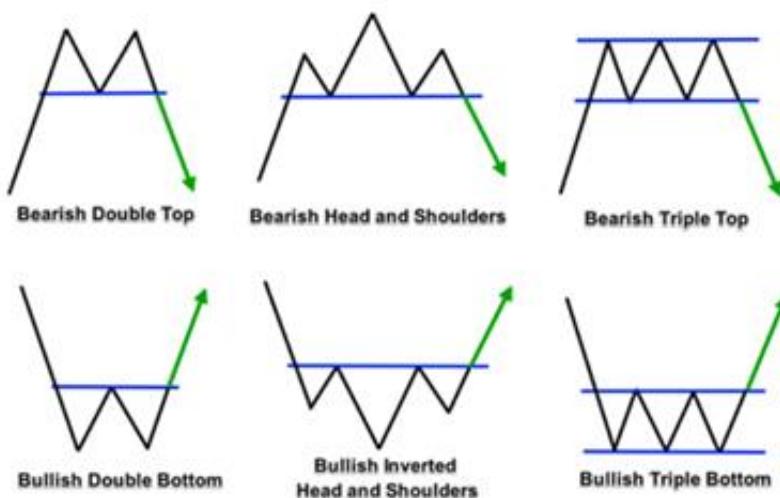
²³ Relative Strength Index (RSI)

که در این رابطه، RS برابر است با میانگین رشد، تقسیم بر میانگین افت. هر چه مقدار این شاخص بیشتر باشد، تعداد و طول شمعهای صعودی نسبت به نزولی بیشتر است و هرچه کمتر باشد، تعداد و طول شمعهای نزولی نسبت به صعودی بیشتر است.

سیگنال‌دهی بر اساس این شاخص معمولاً در کف و سقف‌های قیمتی صورت می‌گیرد. به این صورت که در زیر ۳۰ درصد اشباع فروش و بالای ۷۰ درصد اشباع خرید را داریم. بنابراین با توجه به عدد این شاخص و واگرایی‌های موجود، می‌توان قدرت روند را تشخیص داد. [۲]

۳. تحلیل بر اساس پیرکربندی‌های گرافیکی

در این نوع تحلیل، تلاش بر این است که با کشف خط روند و الگوهای قیمتی، نقاط حمایتی و مقاومتی تعیین شوند. [۱][۲]



شکل ۵ - چند نمونه از الگوهای قیمتی

در شکل بالا الگوهای سر و سرشاره، سقف و کف دوکلو و سقف و کف سه قلو را مشاهده می‌کنیم. این الگوها نمونه‌هایی از الگوهای ساده قیمتی می‌باشند که در سقف‌ها و کف‌های قیمتی ممکن است تشکیل شوند. در الگو سر و سرشاره مشاهده می‌کنیم که این الگو تشکیل شده از دو سقف هم‌سطح بهمند شانه‌ها و یک سقف میانی

بلندر مانند سر می‌باشد. همانطور که در شکل مشاهده می‌شود، در این الگو می‌توان یک خط از انتهای بخش ناحیه میانی رسم کرد، که به آن به اصطلاح خط گردن گفته می‌شود. حال اگر این خط شکسته شود، می‌توانیم انتظار تغییر جهت روند را داشته باشیم. الگوی سقف یا کف دوکلو و سه‌قلو نیز بسیار شبیه‌اند. تفاوتی که با الگوی سر و شانه دارند این است که سقف یا کف‌ها در این الگوها هم‌سطح می‌باشند. [۱] [۲]

۳-۲- مشکلات بازار رمزارزها

چالش اصلی در پیش‌بینی رفتار قیمتی رمزارزها، دستکاری بازار و نوسانات شدید قیمت می‌باشد. در واقع به علت حجم کم این بازار، امکان جابه‌جایی قیمت و دستکاری بازار توسط تعداد کمی وجود دارد. این امر در رمزارزهای جدیدتر و رمزارزهایی که در دست تعداد محدودی از افراد می‌باشند، شدیدتر است و در نتیجه باعث می‌شود که نتوان در پیش‌بینی به دقت مناسبی دست یافت. همینطور، برای بسیاری از این رمزارزها داده کافی برای انجام فرایند یادگیری وجود ندارد. با توجه به این مشکلات، تصمیم بر این شد که در این پروژه مدل خود را برای سه ارز بیت‌کوین، اتریوم و ریپل آموزش و ارزیابی کنیم. زیرا این سه از قدیمی‌ترین ارزها در بازار رمزارزها هستند و داده‌های بهروز آن‌ها نیز در دسترس می‌باشد. همچنین بیشترین حجم بازار را دارند که به این دلیل نوسانات شدید و دستکاری‌ها در آن‌ها کمتر است و در نتیجه برای هدف این پروژه مناسب‌تر هستند.

فصل ۳

شبکه‌های عصبی

۱-۳- پیدایش شبکه‌های عصبی

در عصر حاضر شبکه‌های عصبی مصنوعی یا به اختصار شبکه‌های عصبی، به علت ویژگی‌هایی نظیر پردازش موازی، هوشمندی و انعطاف‌پذیری جایگاه ویژه‌ای در حوزه هوش مصنوعی و حل مسائل پیچیده‌ای از قبیل شناخت الگو، دسته‌بندی، تخمین و تشخیص و پیش‌بینی دارند.

شبکه عصبی مصنوعی یک مدل ریاضیاتی است، که عملکرد آن الهام گرفته از شبکه‌های عصبی بیولوژیکی موجود در مغز انسان، که وظیفه پردازش اطلاعات را بر عهده دارند، می‌باشد. بطور کلی، این شبکه تلاش می‌کند که روابط اساسی را در میان یک مجموعه‌ای از داده را شناسایی کند.

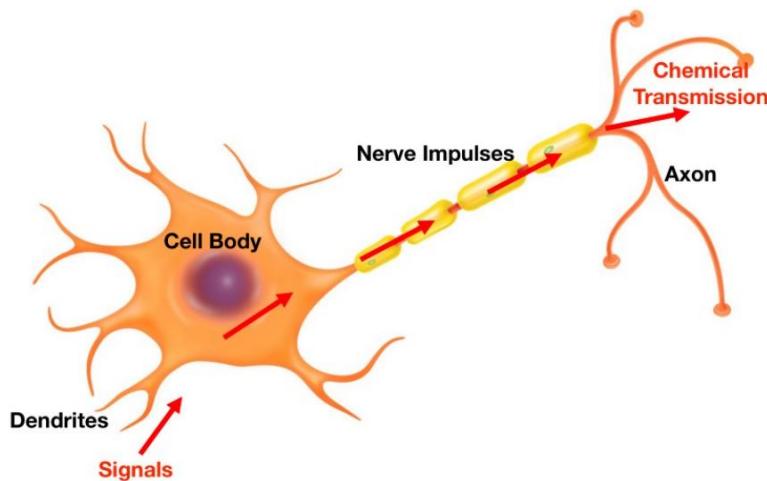
نورون عنصر اصلی مغز است و به تنها یی مانند یک واحد پردازش منطقی عمل می‌کند. سه بخش اصلی نورون های بیولوژیکی دندریت^{۲۴}، جسم سلولی^{۲۵} و آکسون^{۲۶} می‌باشند. دندریت نقش ورودی‌های نورون را دارند و پیام های الکتریکی را دریافت و به بقیه اجزا هدایت می‌کنند. جسم سلولی هسته نورون می‌باشد و نقش فرماندهی را بر عهده دارد و آکسون نقش خروجی‌های نورون را دارند. پس از اینکه پیام عصبی توسط جسم سلولی نورون پردازش شد، توسط آکسون‌ها به بیرون و به سمت سلول‌های دیگر می‌روند. رابطه بین ورودی و خروجی با فرض اینکه هر ورودی یک ولتاژ داشته باشد، به اینصورت است که اگر مجموع این ولتاژ‌ها از حد آستانه^{۲۷} بیشتر شود، آکسون یک شلیک بصورت پالس فرکانسی انجام می‌دهد.

²⁴ Dendrite

²⁵ Soma

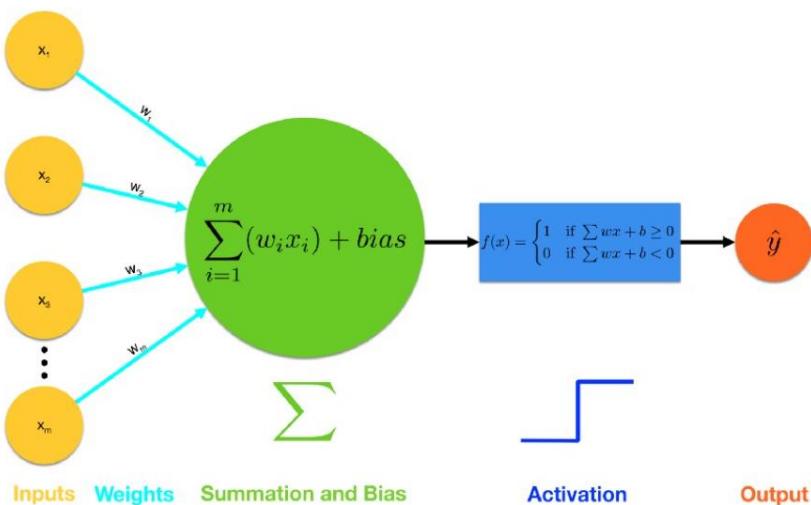
²⁶ Axon

²⁷ Threshold



شکل ۶ - اجزای شبکه عصبی بیولوژیکی

در ابتدا نمونه‌های ساده‌ای از شبکه‌های عصبی به صورت مدارهای الکتریکی پیاده‌سازی شدند. ولی از دهه ۱۹۵۰، محققان سعی در تبدیل این نمونه‌ها به مدل‌های محاسباتی کردند. رزنبلات^{۲۸} در سال ۱۹۵۸ برای اولین بار ایده پرسپترون^{۲۹} را پیاده‌سازی کرد، که در واقع یک مدل ریاضی ساده از نورون است، که آن را نورون مصنوعی نیز می‌نامند.



شکل ۷ - مدل تک پرسپترون

²⁸ Frank Rosenblatt

²⁹ Perceptron

اما این مدل برای مسائل پیچیده‌تر قابل استفاده نبود. زیرا تنها می‌توانست دسته‌بندی خطی انجام دهد. ولی همین مدل، پایه‌ای برای شبکه‌های عصبی امروزی شد.

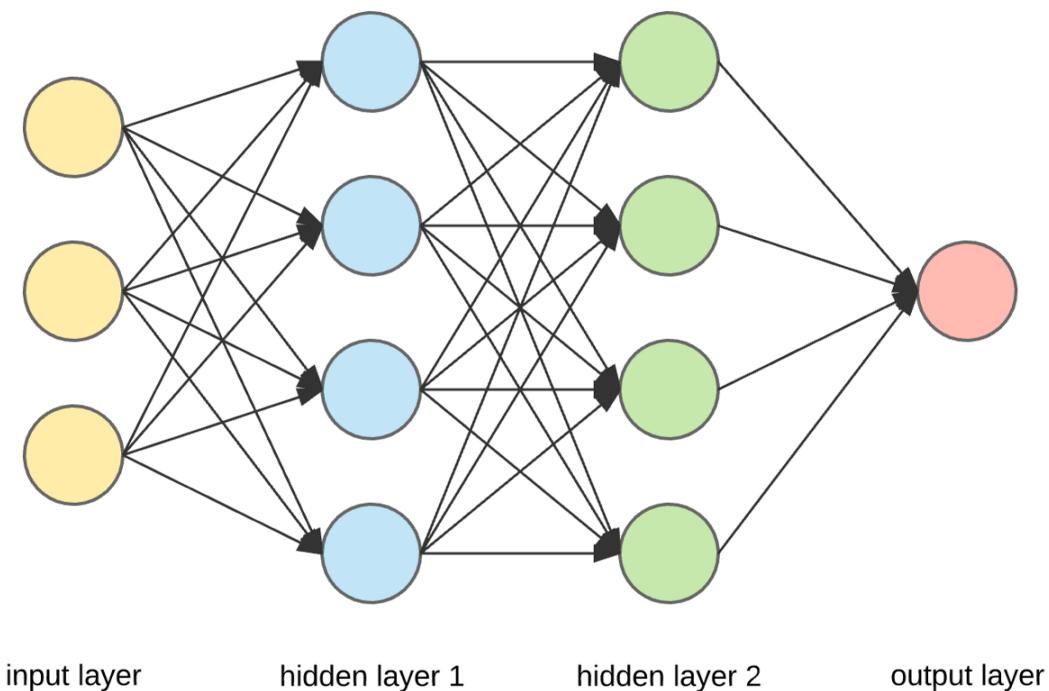
۲-۳- اجزا شبکه‌های عصبی

یک شبکه عصبی رایج، از یک لایه ورودی^{۳۰}، یک لایه خروجی^{۳۱} و حداقل یک لایه پنهان تشکیل شده است، که هر لایه تشکیل شده از تعدادی نورون می‌باشد.

- **لایه ورودی:** لایه اول شبکه است. این لایه ورودی‌ها را دریافت می‌کند و آن‌ها را به سمت لایه‌های بعدی انتقال می‌دهد.
- **لایه پنهان:** لایه میان لایه ورودی و لایه خروجی می‌باشد. هر شبکه می‌تواند یک یا چند لایه پنهان داشته باشد. به‌طورکلی لایه‌های پنهان تبدیل غیرخطی ورودی‌های وارد شده به شبکه را انجام می‌دهند. در واقع عملکرد خوب شبکه و توانایی حل مسائل پیچیده و پردازش داده‌هایی که بصورت خطی تفکیک‌پذیر نیستند، به وجود این لایه‌ها وابسته است. در شبکه‌های عصبی ساده معمولاً یک لایه پنهان و در شبکه‌های عمیق، تعداد این لایه‌ها بیشتر است.
- **لایه خروجی:** لایه آخر شبکه می‌باشد، که شامل خروجی‌های شبکه است.

³⁰ Input Layer

³¹ Output Layer



شکل ۸ - ساختار شبکه عصبی مصنوعی با دو لایه پنهان

همچنین جهت درک محاسبات شبکه، نیاز است که موارد زیر را تعریف کنیم.

- **وزن‌ها^{۳۲}:** جز فراپارامترهای مدل می‌باشند. وزن‌ها نقش بسیار مهمی در فرآیند یادگیری دارند. در واقع مقادیری هستند که در هر لایه در مقدار نورون‌ها ضرب می‌شوند. در واقع ضریب‌هایی هستند که میزان تاثیر هر نورون را مشخص می‌کنند.
- **بایاس‌ها^{۳۳}:** مقداری است که پس از محاسبه ترکیب خطی ورودی‌ها و وزن‌ها با معادله جمع می‌شود. در واقع اضافه کردن یک مقدار بایاس، می‌تواند حد آستانه را تغییر دهد. وزن‌ها شبی نمودار را تعیین می‌کنند و وجود بایاس در کنار آن‌ها برای شیفت دادن نمودار ضروری است. در این صورت می‌توان معادله خط‌های مختلف را مدل کرد.

³² Weight

³³ Bias

- تابع فعال‌ساز^{۳۴}: تابعی که تصمیم می‌گیرد که یک نورون فعال شود یا خیر. در واقع این تابع ترکیب خطی را به عنوان ورودی می‌گیرد و آن را به یک بازه‌ای نگاشت می‌کند. این بازه و نوع نگاشت بستگی به نوع تابع فعال‌ساز مورد استفاده دارد. به کمک تابع فعال‌ساز می‌توان مدل را بصورت غیرخطی مدل کرد. [۳]

۳-۳-۳- مرافق شبکه‌های عصبی

شبکه‌های عصبی اغلب شامل دو مرحله اصلی هستند.

- انتشار رو به جلو^{۳۵}: در این مرحله خروجی شبکه مشخص می‌شود. در این مرحله، در هر لایه جمع وزن دار ورودی‌ها به همراه یک مقدار بایاس به تابع فعال‌ساز داده می‌شود تا خروجی لایه را مشخص کند. این عملیات از لایه ورودی شروع می‌شود و پس از گذر از لایه پنهان درنهایت مقدار خروجی را مشخص می‌کند.
- انتشار وارون^{۳۶}: این مرحله به منظور آموزش شبکه انجام می‌گردد. به این صورت که پس از انجام مرحله انتشار رو به جلو و محاسبه خروجی، بر اساس معیار مشخص شده، میزان خطای خروجی مشخص می‌شود. نیاز به ذکر است که یادگیری شبکه‌های عصبی اغلب به صورت بانظارت^{۳۷} می‌باشد و در واقع به داده‌های واقعی و یا برچسب‌ها برای محاسبه میزان خطای مدل نیاز داریم. سپس، از لایه آخر بصورت مخالف حرکت می‌کنیم تا وزن‌ها و بایاس‌ها را به گونه‌ای تغییر دهیم که میزان خطای به کمترین مقدار برسد. الگوریتم‌های محاسباتی یادگیری انتشار وارون بسیار متنوع و با نتایج و عملکردهای متفاوت هستند. در ساده‌ترین الگوریتم، وزن‌ها و بایاس‌ها در جهت حداقل کردن تابع

³⁴ Activation Function

³⁵ Feed Forward

³⁶ Back Propagation

³⁷ Supervised

هزینه (که گرادیان خطای قضاوت خروجی شبکه است) تغییر می‌کنند. لذا، در هر مرحله آموزش ضرایب وزنی به قرار زیر تغییر می‌یابد.

$$(W, b) = (W, b) - \alpha \nabla Cost$$

که در آن W نمودار وزن‌ها، b نمودار بایاس‌ها و α ضریب یادگیری^{۳۸} است. این روش، الگوریتم کاهش گرادیان^{۳۹} نامیده می‌شود. همچنین به روزرسانی مقادیر می‌تواند به دو صورت افزایشی و یا بسته‌ای^{۴۰} پیاده‌سازی شود. در روش افزایشی، گرادیان خطای هر بار مشاهده یک داده آموزشی محاسبه و وزن‌ها و بایاس‌ها به روزرسانی می‌شوند. در حالت بسته‌ای، میزان خطای هر بار از داده‌های آموزش در هر مرحله محاسبه و سپس به روزرسانی انجام می‌شود. [۳]

$$\nabla Cost = \frac{1}{\#samples} \sum_{samples} \nabla Cost \text{ for the sample}$$

۴-۳- یادگیری عمیق

این اصطلاح در واقع به شبکه‌های پیچیده اشاره دارد. در این شبکه‌ها تعداد گره‌ها در هر لایه و همچنین تعداد لایه‌های پنهان زیادتر و به اصطلاح عمیق هستند. در واقع ایده اصلی این است که با عمیق‌تر کردن شبکه بتوان مسائل پیچیده‌تری را مدل و حل کرد. شبکه‌های چندلایه پرسپترون^{۴۱}، شبکه‌های عصبی پیچشی^{۴۲} و شبکه‌های بازگشتی از گونه‌های محبوب مدل‌های یادگیری عمیق می‌باشند.

³⁸ Learning Rate

³⁹ Gradient Descent Algorithm

⁴⁰ Batch Mode

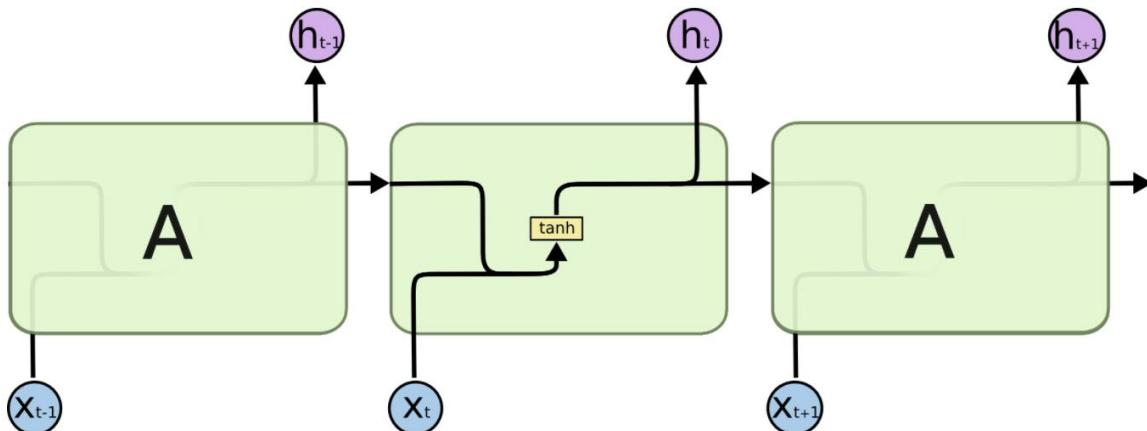
⁴¹ Multi-Layer Perceptron (MLP)

⁴² Convolutional Neural Networks(CNN)

۳-۵-۳- شبکه‌های عصبی بازگشتی

شبکه عصبی بازگشتی که به آن شبکه عصبی مکرر نیز گفته می‌شود، نوعی از شبکه عصبی مصنوعی است که در تشخیص گفتار^{۴۳}، پردازش زبان طبیعی و همچنین در پردازش داده‌های زمانی و ترتیبی استفاده می‌شود.

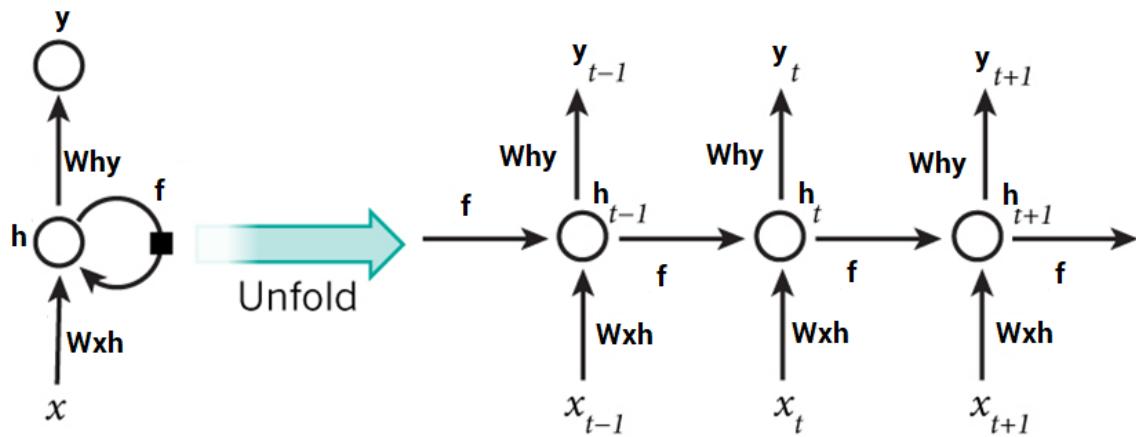
بسیاری از شبکه‌های عمیق شبکه‌های پیش‌خور^{۴۴} هستند و در واقع فرض می‌شود که داده‌ها از یکدیگر مستقل هستند و اطلاعات داده‌های قبلی به حافظه سپرده نمی‌شوند. اما این شبکه‌ها برای بعضی از مسائل که میان داده‌ها وابستگی وجود دارد، مانند زمانی که بخواهیم کلمه بعدی را در یک جمله پیش‌بینی کنیم یا زمانی که بخواهیم داده‌های قیمتی ترتیبی بازارهای مالی را پردازش کنیم، مناسب نیستند. اما شبکه‌های عصبی بازگشتی یک حلقه بازخورد دارند که در آن لایه پنهان شبکه به همراه ورودی بعدی، به شبکه بازگردانده می‌شود. یک شبکه بازگشتی می‌تواند اطلاعات ورودی قبلی خود را به خاطر بسپارد و از این حافظه برای پردازش دنباله‌ایی از ورودی‌ها استفاده کند. به بیان ساده، شبکه‌های عصبی بازگشتی شامل یک حلقه بازگشتی هستند، که موجب می‌شود که اطلاعاتی را که از لحظات قبلی بدست آورده ایم، کاملاً از بین نرون‌های خود بخشی از آن‌ها در شبکه حفظ و در پردازش‌های بعدی اعمال شوند.



شکل ۹ - ساختار سلول‌های شبکه بازگشتی ساده

⁴³ Speech Recognition

⁴⁴ Feed Forward Neural Network



شکل ۱۰ - نمایش بازشده شبکه‌های بازگشتی

در یک شبکه بازگشتی، به ازای تعداد گام زمانی^{۴۵} یا بطور کلی به ازای سایز پنجره‌ای از داده‌های ترتیبی مورد بررسی، کپی‌ای از شبکه را خواهیم داشت؛ که در هر حالت^{۴۶}، علاوه بر ورودی آن حالت، خروجی لایه پنهان حالت قبل را به عنوان ورودی دریافت خواهد کرد. در واقع برای حالت فعلی خواهیم داشت:

$$h_t = f(h_{t-1}, x_t)$$

با اعمال تابع فعال‌ساز:

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

در این فرمول W وزن، h تکبردار نهان، W_{hh} وزن حالت نهان قبلی، W_{xh} وزن حالت ورودی کنونی و \tanh تابع فعال‌سازی است، که با استفاده از توابع فعال‌سازی غیرخطی، خروجی را فشرده می‌کند تا در بازهی $[-1, 1]$ [جای گیرند].

خروجی:

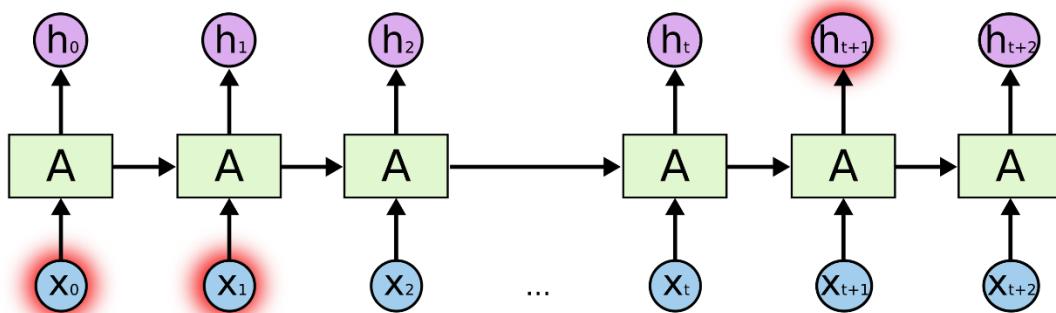
⁴⁵ Time Step

⁴⁶ State

$$y_t = W_{hy} h_t$$

اما شبکه‌های بازگشته ساده چند مشکل اساسی دارند.

باتوجه به موارد گفته شد، در تئوری می‌توان در مسائل مختلف از این شبکه برای پردازش داده‌های ترتیبی استفاده نمود. اما در عمل چند مشکل بزرگ وجود دارد. درصورتی که فاصله اطلاعات مورد نیاز در شبکه زیاد نباشد، این شبکه می‌تواند مناسب باشد. اما درصورتی که گامزمانی و یا پنجره مورد بررسی طولانی باشد، مشکل ناپدید شدن گرادیان^{۴۷} و یا انفجار گرادیان^{۴۸} را خواهیم داشت، بخصوص در مرحله انتشار وارون.



شکل ۱۱ - فاصله زیاد گام‌های زمانی اطلاعات مورد نیاز

در آینده به منظور حل این مشکل معماری‌های جدیدی از شبکه‌های بازگشته، از جمله مدل حافظه کوتاه مدت ماندگار و مدل واحد بازگشته دروازه‌ای پدید آمدند.

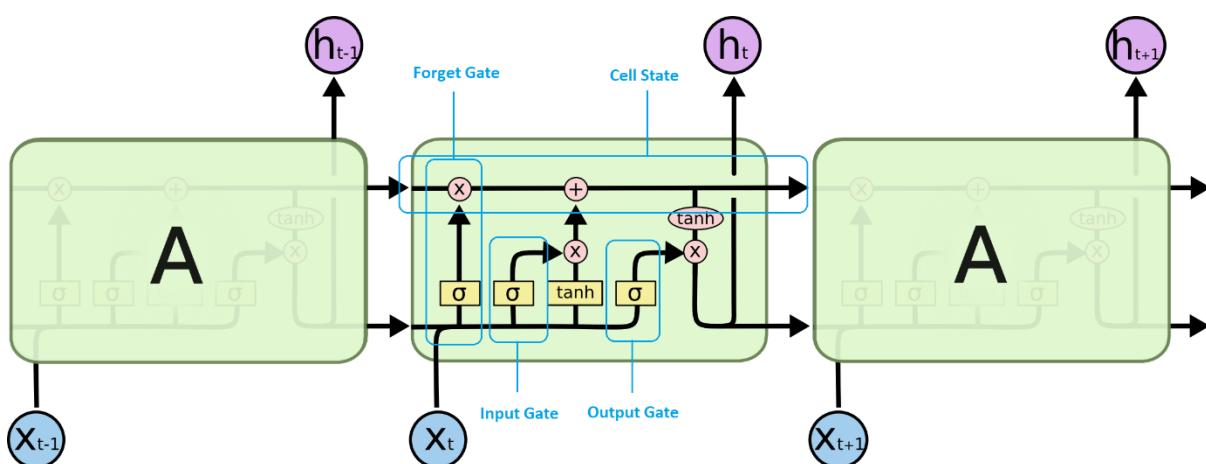
⁴⁷ Vanishing Gradient

⁴⁸ Gradient Explosion

۱-۵-۳ مدل حافظه کوتاه مدت ماندگار^{۴۹}

نوعی از شبکه‌های بازگشتهای ساده، قابلیت یادگیری وابستگی‌های طولانی مدت را دارند. در واقع این تفاوت در معماری واحد شبکه، به آن‌ها این قابلیت را می‌دهد تا به راحتی این اطلاعات را به یاد بیاورند. از این‌رو، شبکه حافظه کوتاه مدت ماندگار امروزه بسیار پرطرفدار است و در مسائل مختلفی مورد استفاده قرار می‌گیرد. [۳]

تمامی شبکه‌های بازگشتهای ساده، تشکیل شده از یک زنجیره تکرار شونده از سلول‌های شبکه است. این سلول در شبکه‌های بازگشتهای ساده، تنها یک تابع فعال‌ساز \tanh را شامل می‌شد. اما معماری ساختار سلول حافظه کوتاه مدت ماندگار پیچیده‌تر می‌باشد. در واقع معماری این مدل شامل مکانیزم‌های داخلی‌ای که دروازه^{۵۰} نامیده می‌شوند، می‌باشد، که جریان اطلاعات را تنظیم می‌کنند.



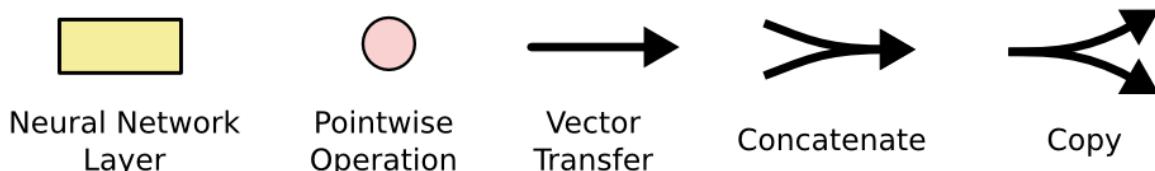
شکل ۱۲ - ساختار سلول‌های شبکه حافظه کوتاه مدت ماندگار

این دروازه‌ها می‌توانند بیاموزند که چه اطلاعاتی مهم هستند و باید آن‌ها را حفظ کند و چه اطلاعاتی را فراموش کند. در ادامه به بررسی این بخش‌ها می‌پردازیم.

⁴⁹ Long Short-term memory (LSTM)

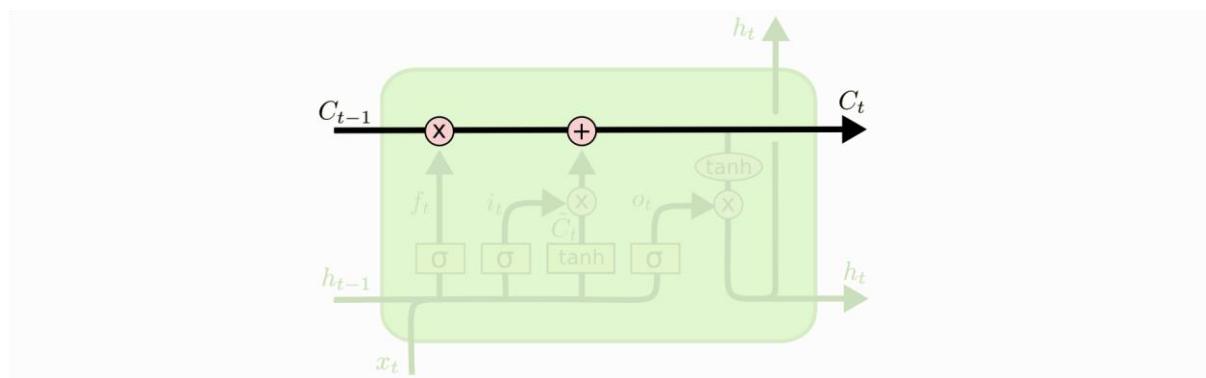
⁵⁰ Gate

در اشکال شبکه علائم استفاده شده به صورت زیر می‌باشد.



شکل ۱۳ - معنای علائم استفاده شده در شبکه

یک بخش اصلی حافظه کوتاه مدت ماندگار حالت سلول^{۵۱} در بخش بالایی است، که جریان اطلاعات از این بخش در میان شبکه و در صورت نیاز با اعمال تغییراتی به سلول‌های بعدی انتقال پیدا می‌کند.

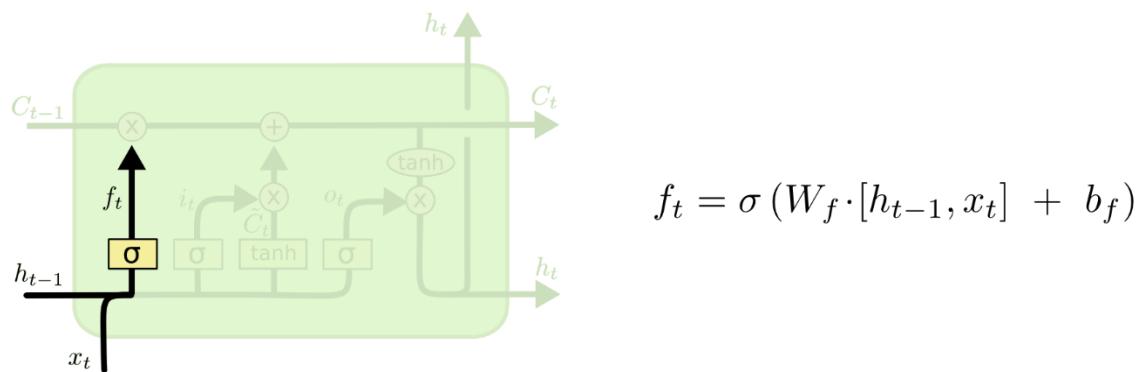


شکل ۱۴ - نمایش حالت سلول در شبکه حافظه کوتاه مدت ماندگار

با توجه به دو دروازه موجود در در این مسیر، بخشی از اطلاعات می‌توانند حذف شوند و به اصطلاح فراموش شوند و همچنین اطلاعات جدید اضافه شوند.

در مرحله اول دروازه فراموشی در بخش چپ سلول باید تعیین کند که چه اطلاعاتی در حالت سلول حذف شوند.

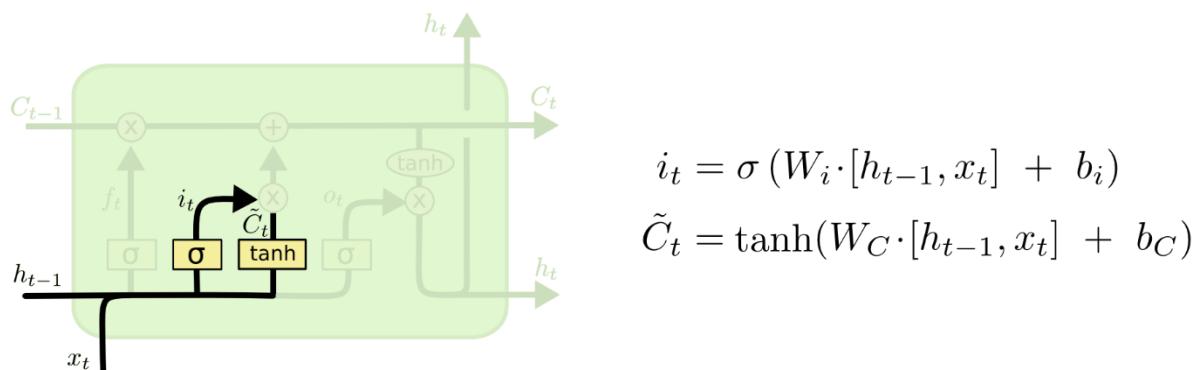
⁵¹ Cell State(Memory State)



شکل ۱۵ - دروازه فراموشی در شبکه حافظه کوتاه مدت ماندگار

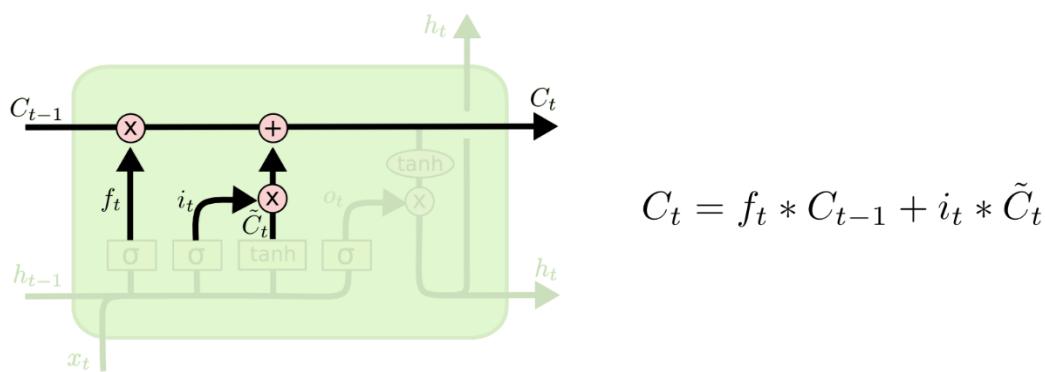
این عملیات با اعمال یک تابع sigmoid که مقداری بین صفر و یک دارد و بر اساس ورودی فعلی و خروجی لایه پنهان حالت قبلی تعیین می‌شود.

در مرحله بعدی، در بخش میانی، تصمیم گرفته می‌شود که چه اطلاعات جدیدی به حالت سلول اضافه شود. این مرحله شامل دو بخش است. در ابتدا با اعمال تابع tanh به ورودی‌ها مشخص می‌شود که چه اطلاعاتی برای انتقال به حالت بعدی کاندید شوند. در بخش بعدی با اعمال تابع sigmoid بر ورودی‌ها و ضرب خروجی آن در نمودار کاندیدها مشخص می‌شود که چه اطلاعاتی به حالت سلول اضافه شوند.



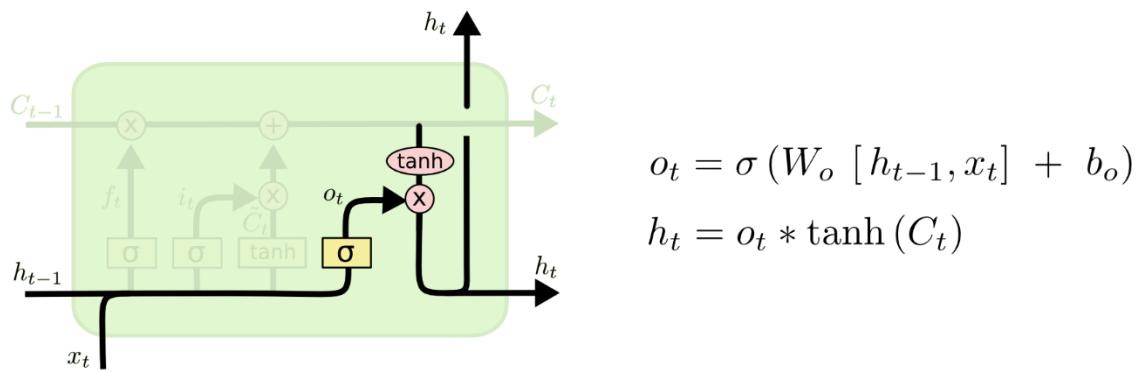
شکل ۱۶ - دروازه ورودی در شبکه حافظه کوتاه مدت ماندگار

در ادامه عملیات‌های انجام شده بر روی حالت سلول اعمال می‌شود و این اطلاعات به سمت سلول بعدی حرکت می‌کنند.



شکل ۱۷ - اعمال تغییرات در حالت سلول شبکه حافظه کوتاه مدت ماندگار

در مرحله آخر، برای تعیین خروجی، اطلاعات حالت سلول پس از اعمال تابع \tanh ، با اعمال یک فیلتر حاصل از تابع sigmoid بر ورودی‌ها، خروجی تعیین می‌شود.



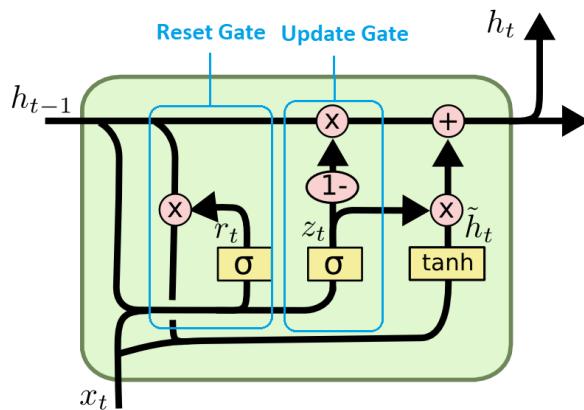
شکل ۱۸ - دروازه خروجی در شبکه حافظه کوتاه مدت ماندگار

۳-۵-۱-۱- مدل واحد بازگشتی دروازه‌ای^{۵۲}

این شبکه مدل جدیدتری از شبکه‌های بازگشتی و گونه‌ای از شبکه حافظه کوتاه مدت ماندگار است. اما تفاوت اصلی این شبکه این است که دیگر حالت سلولی ندارد و از طریق یک حالت پنهان، اطلاعات را انتقال و با دو دروازه ریست و آپدیت عملیات مربوطه را انجام می‌دهد. این شبکه به علت داشتن دو دروازه (یکی کمتر از مدل

⁵² Gated Recurrent Unit (GRU)

حافظه کوتاه مدت ماندگار) و تعداد تنسورهای کمتر، سرعت بیشتری دارد. از این رو این شبکه بسیار مورد توجه قرار گرفته است.



شکل ۱۹ - ساختار سلول واحد بازگشتی دروازه‌ای

در سلول بالا، دو دروازه اصلی ریست و آپدیت را مشاهده می‌کنیم. ساختار این دو دروازه بسیار شبیه است و تفاوت تنها در وزن‌ها می‌باشد.

دروازه ریست تعیین می‌کند که چه میزان از اطلاعات فراموش شوند.

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

در مقابل دروازه آپدیت تعیین می‌کند که چه میزان از اطلاعات به سلول‌های بعدی انتقال پیدا کنند.

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

یک بخش مهم، نمودار کاندید لایه پنهان می‌باشد؛ که در آن براساس خروجی دروازه ریست تعیین می‌شود که چه میزان از اطلاعات قبلی انتخاب شوند. می‌شود.

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

درواقع اگر خروجی دروازه ریست یک باشد، تمامی اطلاعات لایه پنهان قبلی درنظر گرفته می‌شود و اگر خروجی برابر صفر باشد، این اطلاعات کاملاً نادیده گرفته می‌شود.

در نهایت، خروجی لایه پنهان براساس خروجی دروازه آپدیت انتخاب می‌شود. براساس این مقدار، تجمعی بخشی از اطلاعات لایه پنهان قبلی و نمودار کاندید شده به عنوان خروجی به سلول بعدی داده می‌شود.

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

در واقع اگر خروجی دروازه آپدیت برابر یک باشد، تمامی اطلاعات لایه پنهان گام زمانی قبلی نادیده گرفته می‌شود و تمامی نمودار کاندید لایه پنهان که در مرحله قبل محاسبه شد، در نظر گرفته می‌شود. درصورتی که این خروجی برابر صفر باشد، تنها خروجی لایه پنهان قبلی انتقال پیدا خواهد کرد.

فصل ۴

کارهای پیشین

۱-۴- مقدمه

تحقیقات انجام شده در حوزه پیش‌بینی قیمت بازارهای مالی، اغلب در بازارهای سهام و فارکس انجام شده است و پروژه‌های کمتری به حوزه رمزارزها پرداخته‌اند. اما ماهیت و روش‌ها مشابه است و صرفاً تفاوت در داده‌ها می‌باشد.

همچنین با توجه به مفاهیم بازار که در فصل‌های قبل توضیح داده شد، بسیاری از تحقیقات از روش‌های تکنیکی و با استفاده از شاخص‌های قیمتی جهت روند را بررسی می‌کنند. اما این روش‌ها خارج از هدف این پروژه هستند و همچنین تعیین یک استراتژی سود ده نیاز به دانش اقتصاد دارد. بنابراین در این پروژه به این روش نمی‌پردازیم.

۲-۴- کارهای پیشین انجام شده در حوزه یادگیری عمیق

در ادامه تعدادی از تحقیقات انجام شده در حوزه پیش‌بینی قیمت در بازارهای مختلف با استفاده از الگوریتم‌های یادگیری عمیق آورده شده است:

مهلا نیکو و همکارانش^[۴] یک مدل حافظه کوتاه مدت ماندگار ارائه دادند و آن را با نتایج حاصل از شبکه عصبی مصنوعی، رگرسیون بردار پشتیبان^{۵۳} و مدل جنگل تصادفی^{۵۴} مورد مقایسه قرار دادند. طبق نتایج بدست آمده، مدل حافظه طولانی کوتاه- مدت، دقیق‌تری را در پیش‌بینی قیمت پایانی صندوق قابل معامله ishares MSCI انگلستان، ارائه داد.

^{۵۳} Support Vector Regression (SVR)

^{۵۴} Random Forest (RF)

فاضلی و همکارانش^[۵] یک مدل حافظه کوتاه مدت ماندگار ارائه دادند که در آن از تابع فعال‌ساز LeakyReLU استفاده کردند و نشان دادند که از تابع ReLU بهتر عمل می‌کند. همینطور نشان دادند که استفاده از شاخص قدرت نسبی^{۵۵} در الگوریتم خود، میزان خطای کاهش خواهد داد.

نایک و همکارانش^[۶] از مدل حافظه کوتاه مدت ماندگار برای پیش‌بینی بازار سهام استفاده کردند. تحقیقات آن‌ها نشان داد که این مدل می‌تواند رفتار گذشته سهام را در حافظه خود نگه‌داری کند که به کمک آن می‌توان آینده آن را نیز پیش‌بینی نمود. همچنین آن‌ها نشان دادند که این مدل از شبکه عصبی مصنوعی پیش‌خور بهتر عمل می‌کند.

سو و همکارانش^[۷] یک شبکه حافظه کوتاه مدت ماندگار مبتنی بر توجه پیشنهاد دادند. آن‌ها با بررسی توییت‌های خبری مرتبط به بازار سهام و تاثیر آن‌ها در قیمت روز، به دقت بالاتری در پیش‌بینی نسبت به شبکه معمولی حافظه کوتاه مدت ماندگار رسیدند.

حسین و همکارانش^[۸] بر روی مدل حافظه کوتاه مدت ماندگار و مدل واحد بازگشتی دروازه‌ای برای پیش‌بینی شاخص S&P500^{۵۶} استفاده کردند. آن‌ها این دو مدل را با یکدیگر مقایسه کردند و با ترکیب این دو مدل به دقت بالاتری رسیدند.

شیان و همکارانش^[۹] مدل حافظه کوتاه مدت ماندگار را با مدل خود همبسته میانگین متحرک^{۵۷} ترکیب کردند. آن‌ها در نتایج پیش‌بینی قیمت پایانی در بازار سهام، دقت بیشتری نسبت به حالت استفاده از مدل حافظه کوتاه مدت ماندگار به تنها‌ی کسب کردند.

لکشمینارایان و همکارانش^[۱۰] از قیمت طلا و نفت و همچنین از شاخص میانگین متحرک^{۵۸} در کنار مدل حافظه کوتاه ماندگار استفاده کردند. آن‌ها نشان دادند که استفاده از این داده‌ها در کنار مدل خود باعث افزایش

^{۵۵} Relative Strength Index (RSI)

^{۵۶} Standard and Poor's 500

^{۵۷} Autoregressive Integrated Moving Average (ARIMA)

^{۵۸} Moving Average

دقت می‌شود و همچنین نشان دادند که مدل ارائه شده دقته بهتری نسبت به مدل ماشین بردار پشتیبان^{۵۹} ارائه می‌دهد.

رعناء و همکاران [۱۱] یک مدل حافظه کوتاه مدت ماندگار ارائه دادند و نشان دادند که این مدل عملکردی بهتر نسبت به رگرسیون خطی و رگرسیون ماشین پشتیبان دارد. همچنین نتایج حاصل از استفاده از تابع‌های فعال‌ساز و بهینه‌سازهای مختلف را مقایسه کردند. آن‌ها با استفاده از تابع فعال‌ساز \tanh و بهینه‌ساز adam بیشترین دقته را با دقته ۹۸,۴۹ درصد کسب نمودند.

لیو و همکارانش [۱۲] یک مدل تشکیل شده از دو لایه واحد بازگشتی دروازه‌ای و یک لایه حافظه کوتاه مدت ماندگار ارائه دادند. آن‌ها با استفاده از این مدل، دقته بهتری در پیش‌بینی بازار سهام نسبت به استفاده از هر یک مدل به تنها یکی کسب کردند.

۳-۴ - خلاصه

با مطالعه و بررسی تعداد زیادی از تحقیقات انجام شده برای پیش‌بینی قیمت با استفاده از مدل‌های یادگیری عمیق به این نتیجه رسیدیم که شبکه‌های بازگشتی بخصوص مدل‌حافظه کوتاه مدت ماندگار و مدل واحد بازگشتی دروازه‌ای بهترین کارکرد و دقته را دارند. بنابراین در این پژوهه قصد داریم که بر روی این مدل‌ها تمرکز کنیم و پس از ارزیابی، با ترکیب آن‌ها یک مدل نهایی ارائه دهیم. سپس از این مدل در سامانه خود برای پیش‌بینی ارزهای موردنظر استفاده کنیم.

^{۵۹} Support Vector Machine(SVM)

فصل ۵

طراحی و پیاده‌سازی

۱-۵- مقدمه

باتوجه به توضیحات داده شده، در این پروژه قصد داریم که یک سامانه تحت وب برای پیش‌بینی قیمت رمزارزها با استفاده از مدل‌های یادگیری عمیق طراحی کنیم. در ابتدا دو مدل حافظه کوتاه مدت ماندگار و واحد بازگشتی دروازه‌ای را آموزش و پس از ارزیابی و پیدا کردن فراپارامترها^{۶۰}، این دو مدل را با یکدیگر ترکیب و مدل نهایی را طراحی می‌کنیم. در آخر نیز یک سامانه تحت وب برای استفاده از مدل خود توسعه می‌دهیم.

مراحل انجام پروژه:

- دریافت داده‌ها
- پیش‌پردازش و آماده‌سازی داده‌ها
- پیاده‌سازی مدل‌های شبکه عصبی
- پیاده‌سازی سامانه

۲-۵- کتابخانه‌ها و ابزارها

برای انجام این پروژه، در ابتدا از کتابخانه `yfinance` برای دریافت داده‌های رمزارزهای موردنظر بصورت بی‌درنگ استفاده می‌شود. سپس برای طراحی مدل‌های خود از `TensorFlow` و `Keras` استفاده می‌کنیم. باتوجه به هدف پروژه، استفاده از `Keras` بسیار مناسب است و به ما قابلیت‌های مورد نیاز جهت آموزش و ارزیابی و پیداکردن فراپارامترهای مناسب را می‌دهد. در آخر نیز از کتابخانه `streamlit` برای توسعه سامانه تحت وب خود استفاده می‌کنیم.

⁶⁰ Hyperparameters

۱-۲-۵ - کتابخانه yfinance

این کتابخانه تعداد زیادی از داده‌های بازارهای خارجی را دارد. همچنین شامل اخبار از وضعیت سهام‌ها در سرتاسر جهان می‌شود. به طور دقیق‌تر، این کتابخانه به شکل یک رابط برنامه‌نویسی^{۶۱} کاربردی عمل می‌کند که با استفاده از آن به راحتی می‌توانیم داده‌های قیمتی رمزارزهای موردنظر را بصورت لحظه‌ای و بی‌درنگ دریافت کنیم.

۱-۲-۶ - کتابخانه TensorFlو^{۶۲}

یک کتابخانه متن باز و رایگان برای یادگیری ماشین و هوش مصنوعی می‌باشد. این کتابخانه برای مسائل مختلفی می‌تواند مورد استفاده قرار گیرد. اما TensorFlو پراستفاده‌ترین کتابخانه برای توسعه مدل‌های یادگیری عمیق می‌باشد. این کتابخانه در زبان‌های برنامه‌نویسی زیادی از جمله پایتون می‌تواند مورد استفاده قرار گیرد.



TensorFlow

شکل ۲۰ - نماد TensorFlو

^{۶۱} Application Programming Interface (API)

^{۶۲} TensorFlow

۳-۲-۵ - رابط برنامه‌نویسی کراس^{۶۳}

یک رابط برنامه‌نویسی سطح بالا برای پیاده‌سازی شبکه‌های عصبی می‌باشد که در بالاترین سطح تنسورفلو ساخته شده است. کراس بسیار کاربر پسند است و استفاده از آن راحت‌تر از تنسورفلو است. این رابط برنامه‌نویسی با زبان پایتون نوشته شده است.



شکل ۲۱ - نماد کراس

۴-۲-۵ - چارچوب^{۶۴}

یک چارچوب متن باز پایتون است که امکان پیاده‌سازی برنامه تحت وب برای پروژه‌های یادگیری ماشین و علم داده را فراهم می‌کند. این چارچوب از بسیاری از کتابخانه‌های پایتون پشتیبانی می‌کند و قابلیت‌های خوبی برای پیاده‌سازی یک برنامه و نمایش داده‌ها دارد.

⁶³ Keras

⁶⁴ Framework



Streamlit

شکل ۲۲ - نماد streamlit

۳-۵- دریافت داده‌ها

برای دریافت داده‌ها همانطور که گفته شد، قصد داریم که داده‌ها را بصورت بی‌درنگ از طریق رابط کاربری دریافت کنیم. اگرچه مجموعه داده‌های آماده نیز موجود بود. اما این داده‌ها به روز نیستند. با توجه به اینکه قصد داریم یک سیستم کاربردی ارائه دهیم که کاربران بتوانند روزانه از آن استفاده کنند، امکان دریافت داده‌های جدید و آموزش مجدد مدل ضروری است.

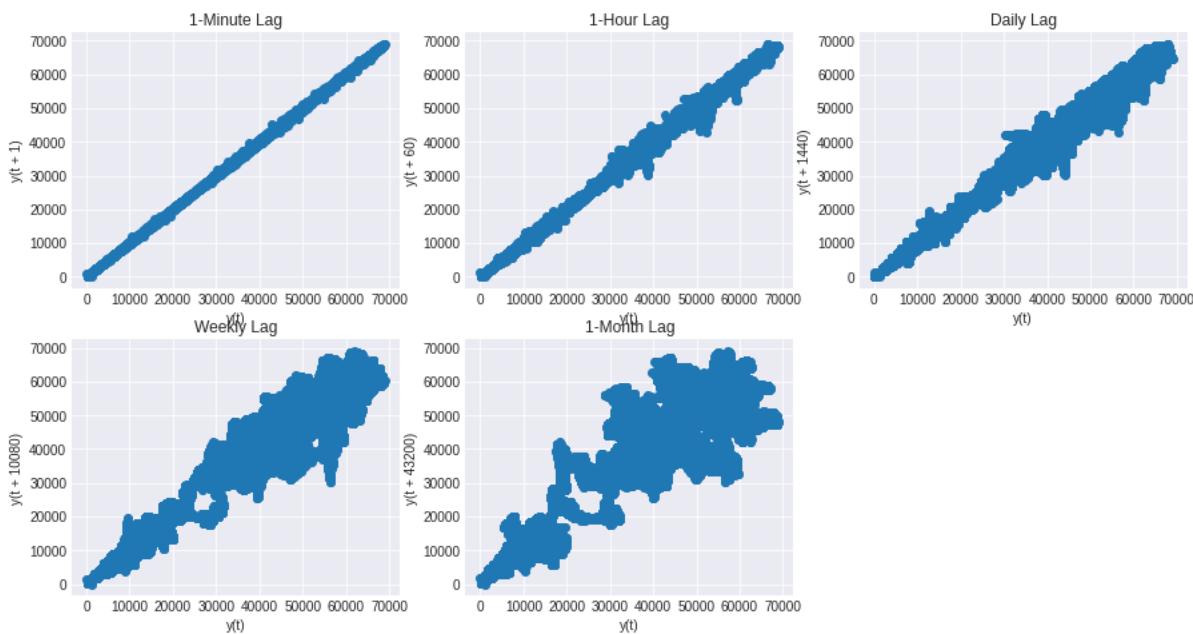
برای محقق کردن این امر، رابطه‌ای برنامه‌نویسی مختلفی بخصوص از سوی صرافی‌ها ارائه می‌شود. اما ما تصمیم گرفتیم که از کتابخانه yfinance استفاده کنیم تا داده‌ها را از یاهو دریافت کنیم. علت این انتخاب، قابل اعتماد بودن و سرعت مناسب آن به هنگام دریافت داده‌ها بود. همچنین این کتابخانه داده‌های بسیاری از رمزارز و سهام‌های معتبر را از جمله سه رمزارزی که قصد بررسی داریم را شامل می‌شود.

به منظور دریافت داده‌ها، باید جفت ارز مربوطه و تاریخ موردنظر را انتخاب کنیم. ما در این پروژه قیمت‌ها را بر پایه دلار بررسی می‌کنیم. بنابراین با نمادهای جفت ارز BTC-USD داده‌های رمزارز بیت‌کوین،

داده‌های رمزارز اتریوم و با XRP-USD داده‌های ریپل را دریافت می‌کنیم. همچنین به منظور داشتن داده‌های کافی، تمامی داده‌های تاریخی ارائه شده توسط رابط کاربری تا به امروز را دریافت می‌نماییم.

باتوجه به نمودار Lag زیر که براساس داده‌های بیت‌کوین محاسبه شده است، مشاهده می‌کنیم که برای دوره‌زمانی دقیقه‌ای، ساعتی و روزانه همبستگی مثبت بین داده‌ها وجود دارد. اما در داده‌های هفتگی و ماهانه همبستگی کم می‌شود و حالت تصادفی پیدا می‌کند. به علاوه، در دوره زمانی هفتگی و ماهانه، داده‌های بسیار کمتری هم خواهیم داشت که ممکن است باعث شود فرایند آموزش به خوبی انجام نشود.

Lag Plots



شکل ۲۳ - نمودارهای lag در دوره‌های زمانی متفاوت رمزارز بیت‌کوین

همچنین در دوره‌های زمانی کوتاه، بخصوص در بازار رمزارزها، بیشتر شاهد نوسانات شدید و دستکاری‌های بازار هستیم. درنتیجه مدل‌های ما نیز در این دوره زمانی به تنها یی نمی‌توانند نتایج مفید و قابل استفاده‌ای ارائه دهند. برای بررسی دوره‌های کوتاه مدت و پر نوسان، نیاز است که روش‌های دیگر، بخصوص استفاده از شاخص‌های حجمی و نوسان‌گر را دخیل کرد. بنابراین، برای این پژوهه دوره‌زمانی روزانه می‌تواند مناسب باشد.

نیاز به ذکر است که در بازار رمزارزها بسیاری از رمزارزها الگویی مشابه به روند بیت‌کوین دارند. زیرا بیت‌کوین قدیمی‌ترین رمزارز می‌باشد و به عنوان ارز پدر شناخته می‌شود و بیشترین حجم بازار را دارد. درنتیجه روند و عملکرد عمدۀ رمزارزها وابسته به آن می‌باشد. بنابراین، ما برای طراحی مدل‌های خود از داده‌های بیت‌کوین استفاده خواهیم کرد.

داده‌های روزانه دریافت شده برای سه رمزارز بیت‌کوین، اتریوم و ریپل به ترتیب در زیر مشاهده می‌کنیم.

	Date	Open	High	Low	Close	Adj Close	Volume
0	2015-01-01 00:00:00+00:00	320.434998	320.434998	314.002991	314.248993	314.248993	8036550
1	2015-01-02 00:00:00+00:00	314.079010	315.838989	313.565002	315.032013	315.032013	7860650
2	2015-01-03 00:00:00+00:00	314.846008	315.149994	281.082001	281.082001	281.082001	33054400
3	2015-01-04 00:00:00+00:00	281.145996	287.230011	257.612000	264.195007	264.195007	55629100
4	2015-01-05 00:00:00+00:00	265.084015	278.341003	265.084015	274.473999	274.473999	43962800
...
2831	2022-10-02 00:00:00+00:00	19311.849609	19370.308594	18970.621094	19044.107422	19044.107422	20765955327
2832	2022-10-03 00:00:00+00:00	19044.068359	19653.542969	19025.226562	19623.580078	19623.580078	30484729489
2833	2022-10-04 00:00:00+00:00	19623.583984	20380.343750	19523.839844	20336.843750	20336.843750	35887278685
2834	2022-10-05 00:00:00+00:00	20335.900391	20343.748047	19801.800781	20160.716797	20160.716797	33223790572
2835	2022-10-06 00:00:00+00:00	20161.039062	20408.392578	19900.087891	19955.443359	19955.443359	34711412966

2836 rows × 7 columns

شکل ۲۴ - داده‌های روزانه بیت‌کوین، دریافت شده از طریق رابطه‌ای برنامه‌نویسی yfinance

فصل ۵: طراحی و پیاده‌سازی

	Date	Open	High	Low	Close	Adj Close	Volume
0	2017-11-09 00:00:00+00:00	308.644989	329.451996	307.056000	320.884003	320.884003	893249984
1	2017-11-10 00:00:00+00:00	320.670990	324.717987	294.541992	299.252991	299.252991	885985984
2	2017-11-11 00:00:00+00:00	298.585999	319.453003	298.191986	314.681000	314.681000	842300992
3	2017-11-12 00:00:00+00:00	314.690002	319.153015	298.513000	307.907990	307.907990	1613479936
4	2017-11-13 00:00:00+00:00	307.024994	328.415009	307.024994	316.716003	316.716003	1041889984
...
1788	2022-10-02 00:00:00+00:00	1311.753418	1316.330078	1275.336060	1276.093506	1276.093506	7578351650
1789	2022-10-03 00:00:00+00:00	1276.163452	1326.554443	1271.150879	1323.439209	1323.439209	10153070907
1790	2022-10-04 00:00:00+00:00	1323.278320	1364.970947	1320.076660	1362.126587	1362.126587	10139774963
1791	2022-10-05 00:00:00+00:00	1361.972900	1362.451782	1320.855103	1352.837158	1352.837158	9774451820
1792	2022-10-06 00:00:00+00:00	1352.806641	1380.404907	1349.449951	1351.709473	1351.709473	12033514861

1793 rows × 7 columns

شکل ۲۵ - داده‌های روزانه اتریوم، دریافت شده از طریق رابطه‌ای برنامه‌نویسی yfinance

	Date	Open	High	Low	Close	Adj Close	Volume
0	2017-11-09 00:00:00+00:00	0.217911	0.221791	0.214866	0.217488	0.217488	147916992
1	2017-11-10 00:00:00+00:00	0.218256	0.219068	0.205260	0.206483	0.206483	141032992
2	2017-11-11 00:00:00+00:00	0.205948	0.214456	0.205459	0.210430	0.210430	134503008
3	2017-11-12 00:00:00+00:00	0.210214	0.210214	0.195389	0.197339	0.197339	251175008
4	2017-11-13 00:00:00+00:00	0.197472	0.204081	0.197456	0.203442	0.203442	132567000
...
1788	2022-10-02 00:00:00+00:00	0.475119	0.477434	0.448158	0.448850	0.448850	1524148633
1789	2022-10-03 00:00:00+00:00	0.448868	0.467568	0.439548	0.462879	0.462879	1852548565
1790	2022-10-04 00:00:00+00:00	0.462878	0.484598	0.452967	0.480174	0.480174	2192220219
1791	2022-10-05 00:00:00+00:00	0.480121	0.499331	0.473405	0.489683	0.489683	2480530357
1792	2022-10-06 00:00:00+00:00	0.489699	0.504087	0.489372	0.493184	0.493184	1913140571

1793 rows × 7 columns

شکل ۲۶ - داده‌های روزانه ریبل، دریافت شده از طریق رابطه‌ای برنامه‌نویسی yfinance

مشاهده می‌کنیم که داده‌ها شامل ۷ ستون اطلاعات می‌باشند که به ترتیب برابرند با:

۱. تاریخ: تاریخ داده‌های ثبت شده می‌باشد که مشاهده می‌کنیم بصورت روزانه و در اول هر روز می‌باشد.
۲. قیمت باز شدن: قیمت اول روز می‌باشد. درواقع قیمت ارز مربوطه به هنگام باز شدن شمع روزانه در تاریخ مشخص شده می‌باشد.
۳. قیمت بالای ارز: بالاترین قیمتی که ارز مربوطه در روز مشخص شده داشته است.
۴. قیمت پایین ارز: پایین‌ترین قیمتی که ارز مربوطه در روز مشخص شده داشته است.
۵. قیمت بسته شدن: قیمت پایان روز می‌باشد. درواقع قیمت ارز مربوطه به هنگام بسته شدن شمع روزانه در تاریخ مشخص شده می‌باشد.
۶. قیمت تعديل شده بسته شدن ارز^{۶۵}: مسئله‌ای که با قیمت بسته شدن ارز وجود دارد این است که در اکثر ارزها، به دلیل حجم کم بازار آن‌ها یک نفر می‌تواند در آخر روز با اختلال ایجاد کردن در قیمت ارز، با هدف آن را بالا برد و یا آن را پایین آورد که نشان دهنده قیمت واقعی آن ارز نبوده است. برای برطرف کردن این مشکل، یک قیمت تعديل شده بسته شدن ارز حساب می‌شود که میانگینی از قیمت و وضعیت آن ارز را در طول روز نشان می‌دهد که اثر منفی قیمت لحظه آخر را خنثی کند.
۷. حجم ارز: مقدار کل خرید و فروش شدن ارز مربوطه در آن روز خاص را نشان می‌دهد. طبیعی است که اگر این عدد بزرگ‌تر باشد نشان‌دهنده این است که مردم اشتیاق بیشتری برای فعال‌ساز روی چنین ارزی داشته‌اند.

⁶⁵ Adjusted Closing Price

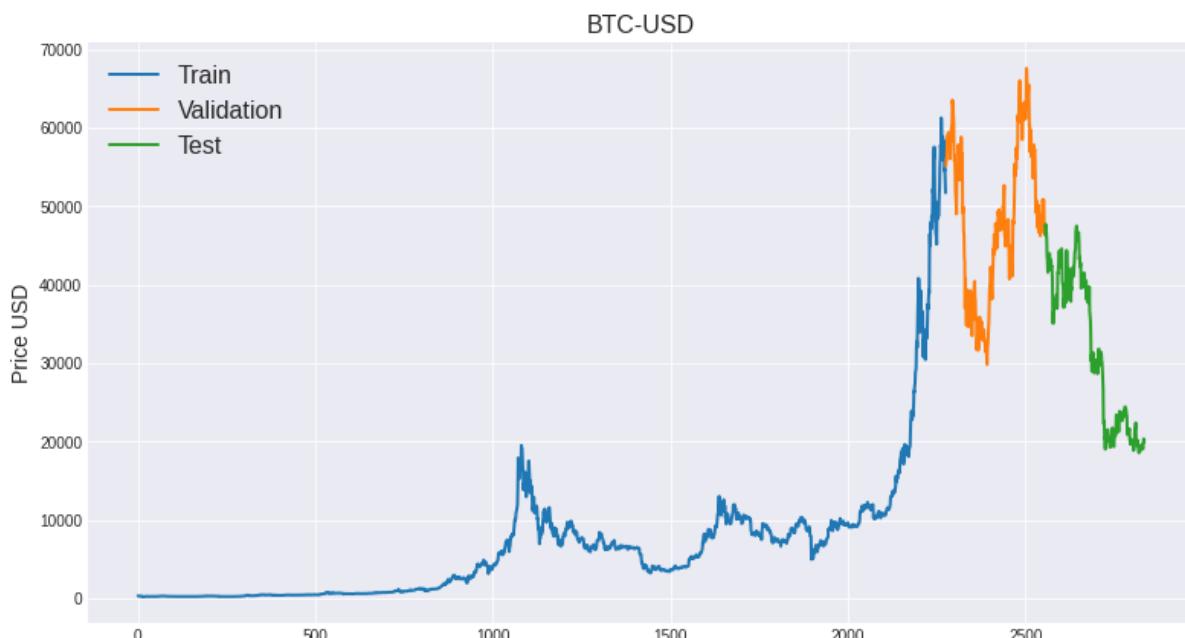
۴-۵- پیش‌پردازش و آماده‌سازی داده‌ها

باتوجه به اینکه هدف اصلی در این پروژه طراحی و ارزیابی مدل‌ها می‌باشد، به منظور کمتر شدن بار محاسباتی، تنها از قیمت‌های پایانی استفاده خواهیم کرد. در صورت پیدا کردن مدل مناسب، می‌توان جهت افزایش دقت، قیمت‌های بالا و پایین و قیمت باز شدن را نیز دخیل کرد.

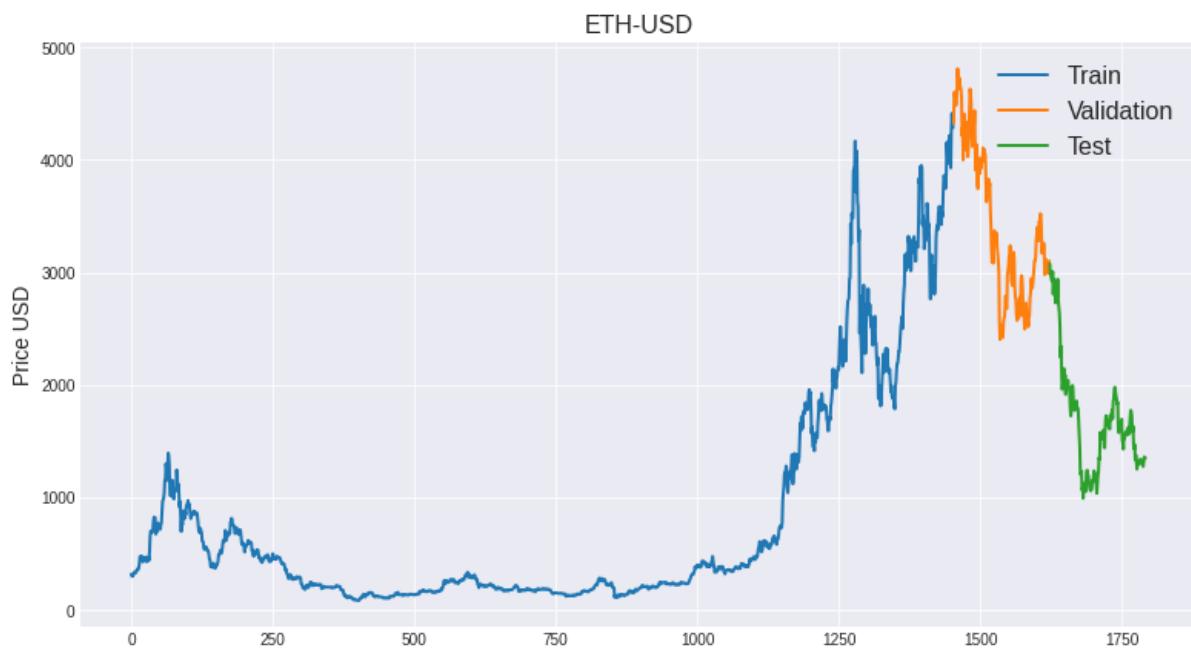
۱-۴-۵- تقسیم داده‌ها

در ابتدا نیاز است که داده‌ها را به سه بخش داده‌های آموزش، اعتبارسنجی و آزمایش تقسیم کنیم. به این منظور حدوداً ده درصد داده‌ها را برای ارزیابی، ده درصد برای آزمایش و باقی را برای آموزش درنظر می‌گیریم. همچنین در این تقسیم‌بندی باید توجه داشت که داده‌ها ترتیبی هستند و ترتیب در این تقسیم‌بندی مهم است.

در ادامه نمودار خطی سه رمزارز را براساس تفکیک انجام شده مشاهده می‌کنیم.



شکل ۲۷ - نمودار قیمت بیت‌کوین پس از تقسیم داده‌ها



شکل ۲۸ - نمودار قیمت اتریوم پس از تقسیم داده‌ها



شکل ۲۹ - نمایش نمودار قیمت ریپل پس از تقسیم داده‌ها

۲-۴-۵- نرمال‌سازی

در قدم بعدی نیاز داریم که داده‌ها نرمال‌سازی شوند تا فرآیند یادگیری، ارزیابی و آزمایش به درستی صورت گیرند. نکته‌ای که باید مورد توجه قرار گیرد این است که در ابتدا باید داده‌ها تقسیم شوند سپس برای هر دسته از داده‌های آموزش، ارزیابی و آزمایش، مقیاس‌های متفاوت درنظر گرفته شود تا بر روی یکدیگر تاثیر نگذارند. در این بخش با درنظر گرفتن مقیاس کننده‌های متفاوت، داده‌های هر دسته را به بازه $[1, 0]$ مقیاس می‌کنیم. این مقیاس‌ها نیز باید حفظ شوند، تا در پایان مقادیر پیش‌بینی بازگردانده شوند.

۳-۴-۵- آماده‌سازی داده‌ها

با توجه به اینکه یادگیری ما بصورت با نظارت است و داده‌ها نیز ترتیبی هستند، نیاز داریم که داده‌ها را به منظور آموزش مدل‌های خود به گونه مناسبی تقسیم کنیم. به‌این‌منظور، باید یک طول به عنوان گام زمانی مدل درنظر بگیریم، که داده‌ها را براساس آن تقسیم‌بندی کنیم. همچنین گام زمانی بعدی را به عنوان برچسب درنظر می‌گیریم. به همین ترتیب پنجره داده‌ها و برچسب‌ها را از ابتدا تا انتهای با یک شیفت مشخص می‌کنیم. به عنوان مثال، اگر داده‌های ما مجموعه ۱ تا ۶ باشد و طول گام زمانی برابر ۳ باشد، تقسیم‌بندی داده‌ها به صورت زیر صورت می‌گیرد.

ورودی مدل	برچسب‌ها
$[1, 2, 3]$	$[4]$
$[2, 3, 4]$	$[5]$
$[3, 4, 5]$	$[6]$

با توجه به توضیحات ارائه شده درمورد شبکه‌های بازگشتی، می‌دانیم انتخاب طول مناسب برای گام زمانی حائز اهمیت می‌باشد. زیرا براساس این گام زمانی و سایز پنجره داده‌ها، مدل می‌تواند الگوها را یاد بگیرد و اطلاعات قبلی را به حافظه بسپارد تا پیش‌بینی بهتری انجام دهد. اما یک طول ثابت بهینه وجود ندارد و این عدد باید بصورت تجربی و با توجه به مسئله تعیین شود. با بررسی و ارزیابی‌های صورت گرفته و همچنین با درنظر گرفتن

نمودار رمざرزاها، ما طول ۱۰۰ را به عنوان گام زمانی درنظر گرفتیم، که به مدل این امکان را می‌دهد تا الگوهای تاریخی را بهتر یاد بگیر و از اطلاعات قبلی برای پیش‌بینی استفاده نماید.

در کد زیر نحوه تقسیم‌بندی داده‌ها و در نهایت ابعاد آن‌ها قابل مشاهده است. این کد بر روی داده‌های بیت‌کوین اجرا شده است.

```
[58] def dataset_generator_lstm(dataset, look_back=100):
    # A "lookback period" defines the window-size of how many
    # previous timesteps are used in order to predict
    # the subsequent timestep.
    dataX, dataY = [], []
    for i in range(len(dataset) - look_back):
        window_size_x = dataset[i:(i + look_back), 0]
        dataX.append(window_size_x)
        dataY.append(dataset[i + look_back, 0]) # this is the label or actual y-value
    return np.array(dataX), np.array(dataY)

trainX, trainY = dataset_generator_lstm(scaled_train)

validationX, validationY = dataset_generator_lstm(scaled_validation)

testX, testY = dataset_generator_lstm(scaled_test)

print("trainX: ", trainX.shape)
print("trainY: ", trainY.shape)
print("validationX: ", validationX.shape)
print("validationY: ", validationY.shape)
print("testX: ", testX.shape)
print("testY", testY.shape)

trainX: (2178, 100)
trainY: (2178,)
validationX: (180, 100)
validationY: (180,)
testX: (180, 100)
testY (180,)
```

در آخر نیز ابعاد داده‌ها را جهت آموزش مدل تغییر می‌دهیم. ابعاد ورودی شبکه‌ها به صورت [تعداد ویژگی‌ها، طول گام زمانی، تعداد داده‌های آموزشی] و ورودی لایه اول مدل‌ها به صورت [تعداد ویژگی‌ها، طول گام زمانی] می‌باشد.

در قطعه کد زیر ابعاد داده‌ها قابل مشاهده است.

```
trainX = np.reshape(trainX, (trainX.shape[0], trainX.shape[1], 1))

validationX = np.reshape(validationX, (validationX.shape[0], validationX.shape[1], 1))

testX = np.reshape(testX, (testX.shape[0], testX.shape[1], 1))

print("Shape of trainX: ", trainX.shape)
print("Shape of validationX: ", validationX.shape)
print("Shape of testX: ", testX.shape)

input_shape = (trainX.shape[1], trainX.shape[2])
print("Layer input shape: ", input_shape)
```

```
Shape of trainX: (2178, 100, 1)
Shape of validationX: (180, 100, 1)
Shape of testX: (180, 100, 1)
Layer input shape: (100, 1)
```

۵- طراحی و پیاده‌سازی مدل‌ها

در این بخش در ابتدا مدل‌های شبکه عصبی را ایجاد کرده و به ارزیابی هریک می‌پردازیم تا فرآپارامترهای مناسب را تعیین کنیم. در آخر با استفاده از روش‌های یادگیری تجمعی^{۶۶} مدل‌ها را ترکیب می‌کنیم.

۱-۵-۵-۵-۱- مدار حافظه کوتاه مدت ماندگار

همانطور که گفته شد برای پیاده‌سازی این مدل از تنسورفلو و کراس استفاده می‌کنیم. با استفاده از رابط کاربری کراس می‌توانیم به سادگی، از این مدل استفاده کنیم.

پارامترهای ارائه شده توسط این رابطهای برنامه‌نویسی برای یک لایه حافظه کوتاه مدت ماندگار و مقدار پیش‌فرض آن‌ها بصورت زیر می‌باشد.

```
tf.keras.layers.LSTM(  
    units,  
    activation="tanh",
```

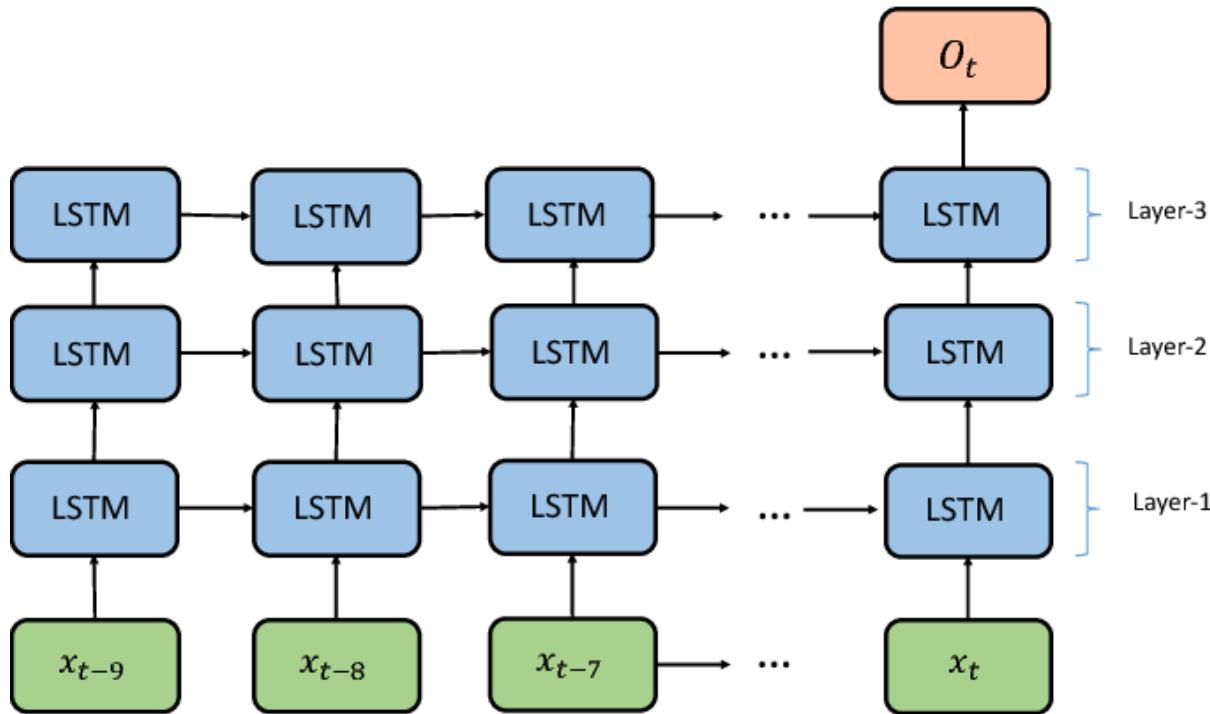
⁶⁶ Ensemble Learning

```
recurrent_activation="sigmoid",
use_bias=True,
kernel_initializer="glorot_uniform",
recurrent_initializer="orthogonal",
bias_initializer="zeros",
unit_forget_bias=True,
kernel_regularizer=None,
recurrent_regularizer=None,
bias_regularizer=None,
activity_regularizer=None,
kernel_constraint=None,
recurrent_constraint=None,
bias_constraint=None,
dropout=0.0,
recurrent_dropout=0.0,
return_sequences=False,
return_state=False,
go_backwards=False,
stateful=False,
time_major=False,
unroll=False,
**kwargs
)
```

در این پژوهه از پارامترها و توابع فعال‌ساز پیش‌فرض این مدل استفاده می‌کنیم و آن‌ها را تغییر نمی‌دهیم. اما برای طراحی معماری شبکه باید تعداد و ساختار لایه‌ها را تعیین کنیم. در واقع علاوه‌بر لایه ورودی و خروجی، می‌توانیم چند لایه از سلول‌های مدل را بصورت پشت سر هم^{۶۷} قرار دهیم، که خروجی سلول‌های لایه قبلی، به

⁶⁷ Stacked

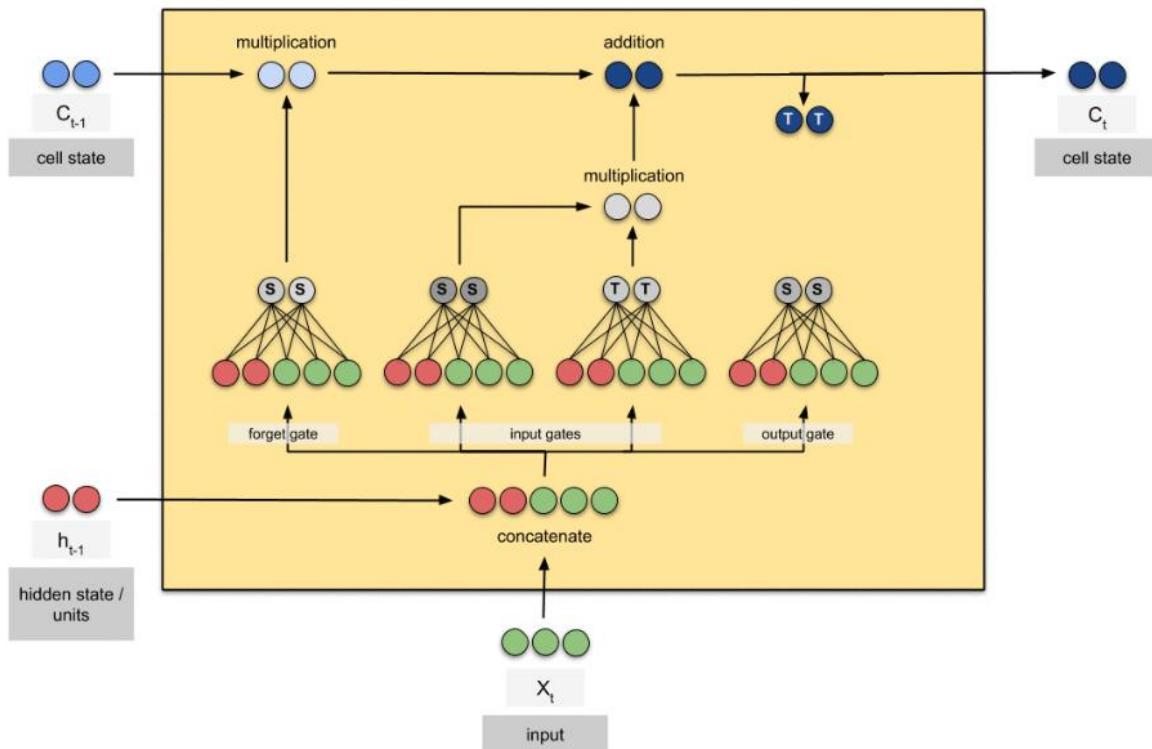
عنوان ورودی سلول‌های لایه بعد در نظر گرفته می‌شوند. برای درک بهتر، در تصویر زیر معماری یک شبکه با سه لایه حافظه کوتاه مدت ماندگار نمایش داده شده است.



شکل ۳۰ - معماری شبکه با سه لایه حافظه کوتاه مدت ماندگار

یک فراپارامتر بسیار مهم که در ساختار لایه‌ها باید تعیین شود، units می‌باشد؛ که در واقع مشخص کننده تعداد واحدهای پنهان^{۶۸} هر لایه و به دنبال آن ابعاد خروجی می‌باشد. در تصویر زیر تعداد واحدهای پنهان برابر ۲ است. مشاهده می‌کنیم که تعداد گرههای حالت پنهان و عملیات‌های درون سلول بر این اساس تعیین می‌شوند.

⁶⁸ Hidden Units



شکل ۳۱ - ساختار سلول حافظه کوتاه مدت ماندگار با دو واحد پنهان

تعیین یک تعداد مناسب برای واحدهای پنهان و همچنین تعداد لایه‌ها، امری دشوار است. به طور کلی، اگر این تعداد زیاد باشد و همچنین شبکه عمیق باشد، می‌توان فرض کرد که مدل توانایی تشخیص الگوهای پیچیده‌تر را دارد. اما از طرف دیگر، اگر این سایزها خیلی زیاد در نظر گرفته شود، تعداد پارامترها نیز بسیار زیاد می‌شود و مدل به سختی می‌تواند یاد بگیرد.

همانطور که گفته شد این فراپارامترها باید به صورت تجربی و براساس مسئله و داده‌هایمان تعیین شود که در ادامه به آن خواهیم پرداخت.

برای پیاده‌سازی شبکه خود با استفاده از کراس، در ابتدا نیاز است که یک مدل ترتیبی ساخته شود. سپس لایه‌های مدل حافظه کوتاه مدت ماندگار را با تعداد واحدهای پنهان دلخواه اضافه می‌کنیم. در آخر نیز، یک لایه

متراکم^{۶۹} با سایز یک اضافه می‌کنیم تا خروجی را بصورت یک عدد که به معنای قیمت پیش‌بینی شده شبکه است، ایجاد کند. در واقع یک لایه کاملاً متصل^{۷۰} است که ورودی آن، خروجی آخرین لایه حافظه کوتاه مدت ماندگار و برابر با تعداد واحدهای پنهان این لایه می‌باشد و خروجی آن یک است.

به طور مثال، در قطعه کد زیر، یک شبکه با دو لایه حافظه کوتاه مدت ماندگار با تعداد واحدهای پنهان ۱۲۸ و ۶۴ ایجاد کردیم. همانطور که مشاهده می‌شود علاوه بر لایه تراکم آخر، یک لایه Dropout با نرخ ۲۰ درصد پس از هر لایه به منظور جلوگیری از بیش‌پردازش قرار داده‌ایم.

```
LSTM_model = Sequential()

LSTM_model.add(LSTM(units = 128, return_sequences = True, input_shape = (trainX.shape[1], trainX.shape[2])))
LSTM_model.add(Dropout(0.2))

LSTM_model.add(LSTM(units = 64, return_sequences = False))
LSTM_model.add(Dropout(0.2))

LSTM_model.add(Dense(units = 1))
```

نکته: پارامتر return_sequences خروجی لایه پنهان را برمی‌گرداند. بنابراین اگر بخواهیم یک لایه حافظه کوتاه مدت ماندگار دیگر اضافه کنیم، باید مقدار این پارامتر برای لایه قبلی True باشد، تا خروجی لایه پنهان آن به عنوان ورودی به لایه بعد داده شود.

در تصویر زیر خلاصه‌ای از ساختار شبکه ایجاد شده و تعداد پارامترهای آن، مشاهده می‌کنیم.

^{۶۹} Dense

^{۷۰} Fully Connected

```
Model: "sequential_50"
```

Layer (type)	Output Shape	Param #
<hr/>		
lstm_16 (LSTM)	(None, 100, 128)	66560
dropout_28 (Dropout)	(None, 100, 128)	0
lstm_17 (LSTM)	(None, 64)	49408
dropout_29 (Dropout)	(None, 64)	0
dense_55 (Dense)	(None, 1)	65
<hr/>		
Total params: 116,033		
Trainable params: 116,033		
Non-trainable params: 0		

۲-۵-۵ - مدل واحد بازگشتی دروازه‌ای

برای پیاده‌سازی شبکه واحد بازگشتی دروازه‌ای نیز از تنسورفلو و کراس استفاده می‌کنیم.

پارامترهای ارائه شده توسط این رابط کاربری برای یک لایه واحد بازگشتی دروازه‌ای و مقدار پیش‌فرض آن‌ها بصورت زیر می‌باشد.

```
tf.keras.layers.GRU(
    units,
    activation="tanh",
    recurrent_activation="sigmoid",
    use_bias=True,
    kernel_initializer="glorot_uniform",
    recurrent_initializer="orthogonal",
    bias_initializer="zeros",
    kernel_regularizer=None,
    recurrent_regularizer=None,
```

```

bias_regularizer=None,
activity_regularizer=None,
kernel_constraint=None,
recurrent_constraint=None,
bias_constraint=None,
dropout=0.0,
recurrent_dropout=0.0,
return_sequences=False,
return_state=False,
go_backwards=False,
stateful=False,
unroll=False,
time_major=False,
reset_after=True,
**kwargs
)

```

همانند قطعه کد زیر می‌توانیم شبکه‌ای از این مدل را از طریق رابط کاربری کراس ایجاد نماییم.

```

# The GRU architecture
GRU_model = Sequential()

GRU_model.add(GRU(units=128, return_sequences=True, input_shape = (trainX.shape[1], trainX.shape[2])))

GRU_model.add(Dropout(0.2))

GRU_model.add(GRU(units=64, return_sequences=False, input_shape = (trainX.shape[1], trainX.shape[2])))

GRU_model.add(Dropout(0.2))

GRU_model.add(Dense(units = 1))

```

در تصویر زیر خلاصه‌ای از ساختار شبکه ایجاد شده و تعداد پارامترهای آن، مشاهده می‌کنیم.

```
Model: "sequential_52"
```

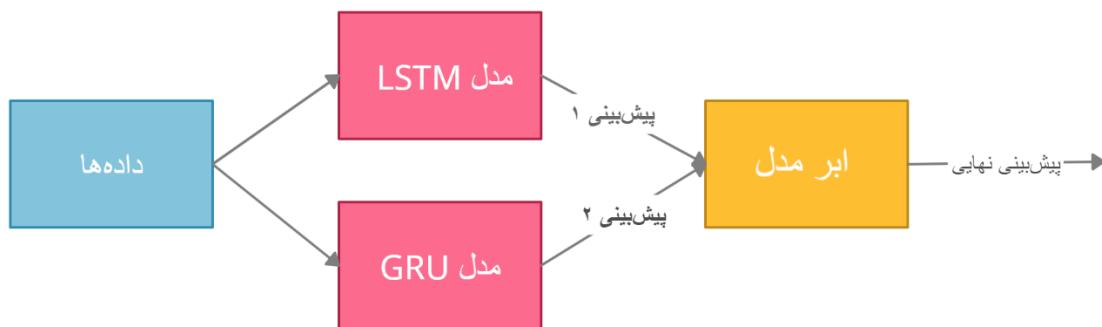
Layer (type)	Output Shape	Param #
<hr/>		
gru_62 (GRU)	(None, 100, 128)	50304
dropout_32 (Dropout)	(None, 100, 128)	0
gru_63 (GRU)	(None, 64)	37248
dropout_33 (Dropout)	(None, 64)	0
dense_58 (Dense)	(None, 1)	65
<hr/>		
Total params: 87,617		
Trainable params: 87,617		
Non-trainable params: 0		

۳-۵-۵ مدل ترکیبی

ترکیب مدل‌ها عموماً به هدف ساخت مدلی با دقت بیشتر به وسیله ترکیب چند مدل ضعیف^{۷۱} یا مدل پایه استفاده می‌شود. همچنین گاهی هدف جلوگیری از بایاس یا واریانس بالا می‌باشد. ما در این بخش قصد داریم مدل‌های آموزش داده شده در بخش‌های قبل را با روش تجمعی Stacking با یکدیگر ترکیب کنیم تا یک مدل قابل اعتمادتر با واریانس کمتر ایجاد کنیم.

روش Stacking گونه‌ای از روش‌های تجمعی می‌باشد که ایده اصلی آن، آموزش چندین مدل پایه ناهمگون و ترکیب آنها از طریق آموزش یک ابرمدل است، تا براساس پیش‌بینی‌های انجام شده توسط مدل‌های پایه، پیش‌بینی نهایی را انجام دهد.

⁷¹ Weak Learner



شکل ۳۲ - ترکیب مدل‌ها با روش تجمعی Stacking

برای طراحی ابر مدل نیز از یک شبکه عصبی کاملاً متصل با دو لایه پنهان به سایزهای ۱۶ و ۸ استفاده می‌کنیم. این مقادیر بصورت تجربی انتخاب شده است. همچنین از تابع فعال‌ساز Leaky ReLU در مدل خود استفاده می‌کنیم. ساختار شبکه به صورت زیر می‌باشد.

```

meta_model = Sequential()

# Desired activation function.
activ_func = LeakyReLU()

# Set input layer and size.
meta_model.add(Flatten(input_shape=(2,)))

# Hidden Layer 1
meta_model.add(Dense(16, activation = activ_func))

# Hidden Layer 2
meta_model.add(Dense(8, activation = activ_func))

# Output Layer
meta_model.add(Dense(1))
  
```

Layer (type)	Output Shape	Param #
<hr/>		
flatten_26 (Flatten)	(None, 2)	0
dense_88 (Dense)	(None, 16)	48
dense_89 (Dense)	(None, 8)	136
dense_90 (Dense)	(None, 1)	9
<hr/>		
Total params:	193	
Trainable params:	193	
Non-trainable params:	0	

نحوه آموزش به این صورت می‌باشد که در ابتدا نتایج پیش‌بینی مدل‌های پایه آموزش داده شده را بر روی داده‌های ارزیابی به دست می‌آوریم. سپس این داده‌ها را در کنار هم قرار داده و به عنوان داده‌های آموزش به ابرمدل می‌دهیم و مقادیر اصلی داده‌های ارزیابی را به عنوان برچسب درنظر می‌گیریم. باید توجه شود که مدل‌های پایه نباید از داده‌های آزمایش استفاده‌ای کنند و تنها پس از آموزش ابرمدل، پیش‌بینی و ارزیابی نهایی بر روی داده‌های آزمایش انجام می‌شوند.

۴-۵-۵- فرآیند آموزش مدل‌ها

آموزش مدل‌ها را با استفاده از بهینه‌ساز^{۷۲} Adam و بصورت دسته‌ای با سایز دسته ۸ و همچنین با ۲۰۰ دوره^{۷۳} Patience Early Stopping با تعداد برابر با ۲۰ نیز به منظور جلوگیری از بیش‌پردازش استفاده می‌کنیم. در واقع یعنی اگر در ۲۰ دوره، میزان خطای داده‌های ارزیابی کاهش نیابد، آموزش متوقف می‌شود.

⁷² Optimizer

⁷³ Epoch

برای محاسبه خطای داده‌های آموزش و ارزیابی نیز از معیار خطای میانگین مربعات^{۷۴} استفاده می‌کنیم.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y - y_i)^2$$

که در آن‌ها y قیمت واقعی، y_i قیمت پیش‌بینی شده توسط مدل و n تعداد پیش‌بینی‌ها می‌باشد.

۵-۵-۵- یافتن فراپارامترهای مناسب

ما در ادامه مدل‌های خود را با ساختارهای متفاوت ایجاد کرده و پس از آموزش، به ارزیابی نتایج می‌پردازیم تا به مجموعه‌ای از فراپارامترهای مناسب برسیم.

ارزیابی را براساس معیار خطای جذر میانگین مربعات^{۷۵} انجام می‌دهیم.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y - y_i)^2}$$

که در این فرمول y قیمت واقعی، y_i قیمت پیش‌بینی شده توسط مدل و n تعداد پیش‌بینی‌ها می‌باشد.

این معیار، با به توان رساندن اختلاف پیش‌بینی انجام شده و مقدار واقعی و سپس جذر گرفتن از مجموع این اختلافات، وزن بیشتری به خطاهای بزرگتر می‌دهد، که درنتیجه باعث می‌شود این معیار در مسائلی مانند پیش‌بینی قیمت که اختلاف زیاد بسیار ناخوشایند است، مناسب باشد.

در جداول زیر نتایج ارزیابی انجام شده از پیش‌بینی‌های دو مدل حافظه کوتاه مدت ماندگار و واحد بر روی داده‌های رمزارز بیت‌کوین، قابل مشاهده است. این نتایج براساس میانگین ۳ بار اجرا محاسبه شده‌اند.

⁷⁴ Mean Squared Error(MSE)

⁷⁵ Root Mean Square Error (RMSE)

جدول ۱ - خطای پیش‌بینی مدل حافظه کوتاه مدت ماندگار با ساختارهای متفاوت

تعداد واحدهای پنهان هر لایه	نرخ Dropout	خطای جذر میانگین مربعات داده‌های آزمایش
[8]	-	۱۰۶۰
[8]	.۲	۱۹۱۷
[64]	-	۱۰۵۰
[64]	.۲	۱۳۴۱
[128]	-	۹۸۴
[128]	.۲	۱۰۰۱
[256]	-	۱۰۱۶
[512]	-	۱۰۶۰
[1024]	-	۱۰۸۶
[8 , 4]	-	۱۳۷۵
[64 , 32]	-	۱۱۵۸
[128 , 64]	-	۱۱۶۸
[128 , 64]	.۱	۱۰۸۶
[128 , 128]	-	۱۲۶۰
[256 , 128]	-	۱۲۴۲

[256 , 256]	-	۱۰۸۴
[64 , 32, 16]	-	۱۴۷۵
[50 , 50, 50]	-	۱۹۱۷

جدول ۲ - خطای پیش‌بینی مدل واحد بازگشتی دروازه‌ای با ساختارهای متفاوت

تعداد واحدهای پنهان هر لایه	نرخ Dropout	خطای جذر میانگین مربعات داده‌های آزمایش
[8]	-	۱۱۰۵
[8]	۰,۲	۹۹۴
[64]	-	۱۱۵۱
[64]	۰,۲	۹۷۵
[128]	-	۱۱۵۶
[128]	۰,۲	۱۰۱۶
[256]	-	۱۰۰۳
[256]	۰,۲	۱۲۷۴
[512]	-	۱۰۱۵
[1024]	-	۲۲۶۸
[8 , 4]	-	۱۱۶۳

[64 , 32]	-	۱۰۱۲
[128 , 64]	-	۱۰۱۹
[128 , 64]	۰,۱	۱۱۳۳
[128 , 128]	-	۱۱۸۹
[256 , 128]	-	۱۰۰۲
[256 , 256]	-	۱۱۵۸
[64 , 32, 16]	-	۱۰۷۳
[50 , 50, 50]	-	۱۳۹۴

با توجه به ارزیابی انجام شده، در صورتی که تعداد واحدهای پنهان کمتر باشد همگرایی بهتر اتفاق می‌افتد، اما به علت اینکه مدل ساده‌تر است به نسبت دقت کمتری نیز حاصل می‌شود. اما هرچه این تعداد بیشتر شود، مدل پیچیده‌تر، پارامترها بیشتر و آموزش مدل سخت‌تر می‌شود. همچنین با افزایش لایه‌ها نیز مدل به خوبی آموزش نمی‌بیند و مقدار خطأ به مراتب بیشتر است. همانطور که در نتایج مشاهده می‌کنیم، با افزایش تعداد لایه‌ها در هر دو مدل، مقدار خطأ به‌طور قابل توجه افزایش پیدا می‌کند. استفاده از تکنیک Dropout در مدل حافظه کوتاه مدت ماندگار کمکی به بهبود نتایج نکرد، اما در بعضی از حالات مدل واحد بازگشتی باعث کاهش خطأ شد.

بر اساس نتایج، با استفاده از یک لایه و تعداد ۱۲۸ واحد پنهان در شبکه حافظه کوتاه مدت ماندگار کمترین خطأ حاصل شد. در شبکه واحد بازگشتی دروازه‌ای نیز با یک لایه و تعداد ۶۴ واحد پنهان و یک لایه Dropout با نرخ ۲۰ درصد، کمترین خطأ بدست آمد.

زمان آموزش مدل حافظه کوتاه مدت ماندگار بر روی مد گرافیک گوگل کولب، بر اساس ساختارهای مختلف بین ۱ تا ۶ دقیقه بود؛ که بسیار زمان خوبی است. به علاوه، این زمان در مدل شبکه واحد بازگشتی دروازه‌ای،

کمتر بود. همانطور که گفته شد، شبکه واحد بازگشتی دروازه‌ای به علت داشتن دو دروازه (یک دروازه کمتر از مدل حافظه کوتاه مدت ماندگار)، تعداد پارامتر و عملیات‌های تنسور^{۷۶} کمتری دارد و سرعت آن بیشتر است.

۵-۶-۵- نحوه پیش‌بینی قیمت روزهای آتی

می‌دانیم که برای ارزیابی مدل‌ها از داده‌های آزمایش استفاده می‌کنیم. به‌اینصورت که برای پیش‌بینی هر روز، براساس گام زمانی تعیین شده، از داده‌های روزهای گذشته استفاده می‌کنیم و در آخر با مقدار واقعی آن روز مقایسه می‌کنیم. اما برای پیش‌بینی روزهای آتی، براساس گام زمانی و داده‌های روزهای آخر، تنها می‌توانیم روز بعد را پیش‌بینی کنیم. حال برای پیش‌بینی روزهای پس از آن، نیاز است که مقدار پیش‌بینی انجام شده را به پنجره داده‌ها اضافه کرده و داده‌ها از انتهای یک شیفت داده شوند و سپس با استفاده از پنجره جدید، روز بعد را پیش‌بینی کنیم و به همین ترتیب ادامه دهیم. اما نیاز به ذکر است که مدل‌های ما برای پیش‌بینی کوتاه مدت مناسب هستند و معمولاً در پیش‌بینی بازه‌های طولانی، همان روندهای ابتدایی را دنبال می‌کنند.

۵-۶- سامانه پیش‌بینی قیمت رمزارزها

برای این پروژه، با استفاده از کتابخانه Streamlit یک سامانه ساده جهت پیش‌بینی قیمت رمزارزها پیاده‌سازی شد.

در ابتدا از کاربر خواسته می‌شود که از میان سه رمزارز ذکر شده، انتخاب کند. سپس کاربر می‌تواند هر یک از سه مدل ارائه شده را جهت انجام پیش‌بینی انتخاب کند. به‌منظور کاهش زمان و بار ترافیکی ما مدل‌های خود را از قبل ذخیره نموده و در اپلیکیشن تنها آن‌ها را فراخوانی می‌کنیم. در آخر نیاز است که تعداد روزهایی که برای پیش‌بینی مدنظر است انتخاب شود.

⁷⁶ Tensor

Stock Forecast App

Select dataset for prediction

BTC-USD

Select model for prediction

Stacked

Days of prediction:

A horizontal slider with a red track and a black dot at the 10 mark. The slider is labeled with '10' above it and '1' and '100' at the ends.

شکل ۳۳ - بخش انتخاب رمざرز، مدل و بازه پیش‌بینی در سامانه

در ادامه، آخرین داده‌های رمزارز مربوطه و همچنین نمودار آن به همراه یک لغزنده^{۷۷} جهت بزرگنمایی بازه دلخواه از نمودار، به کاربر نمایش داده می‌شود.

Loading data... done!

Raw data

	Date	Open	High	Low	Close	Adj Close	Volume
2835	2022-10-06T00:00:00+00:00	20,161.0391	20,408.3926	19,900.0879	19,955.4434	19,955.4434	347114
2836	2022-10-07T00:00:00+00:00	19,957.5586	20,041.0859	19,395.7930	19,546.8496	19,546.8496	292273
2837	2022-10-08T00:00:00+00:00	19,546.3281	19,601.6953	19,299.4141	19,416.5684	19,416.5684	164374
2838	2022-10-09T00:00:00+00:00	19,417.4785	19,542.5391	19,349.2598	19,446.4258	19,446.4258	168372
2839	2022-10-10T00:00:00+00:00	19,446.4160	19,515.4668	19,102.9785	19,141.4844	19,141.4844	274250

شکل ۳۴ - نمایش داده‌های عددی در سامانه

⁷⁷ Slider

Time Series data with Rangeslider

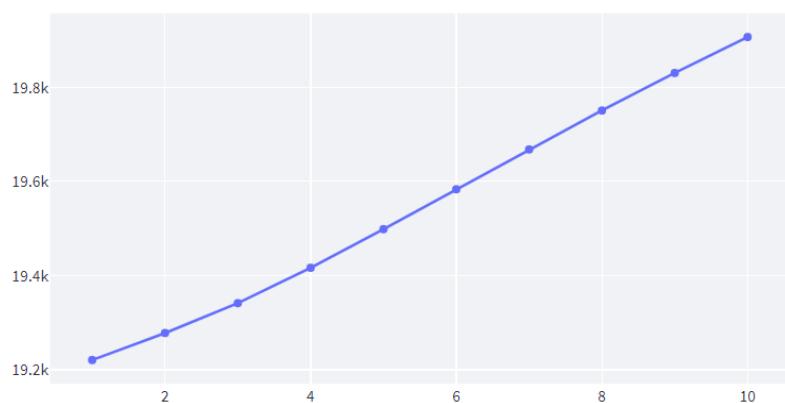


شکل ۳۵ - نمایش نمودار قیمت در سامانه

در آخر قیمت‌های پیش‌بینی شده برای روزهای آتی بصورت عددی و همچنین بصورت نمودار به کاربر نمایش داده می‌شود.

predicted price

0	19,220.5333
1	19,277.9474
2	19,341.3572
3	19,416.4494
4	19,498.4280
5	19,583.0982
6	19,667.6420
7	19,750.3076
8	19,830.0711
9	19,906.3680



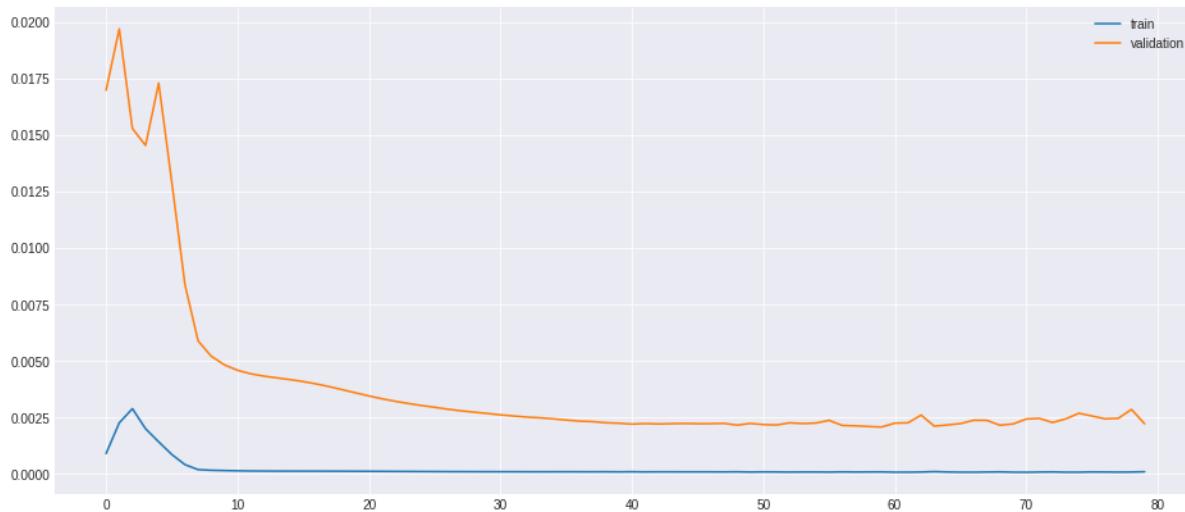
شکل ۳۶ - نمایش نتایج پیش‌بینی‌ها در سامانه

فصل ۶

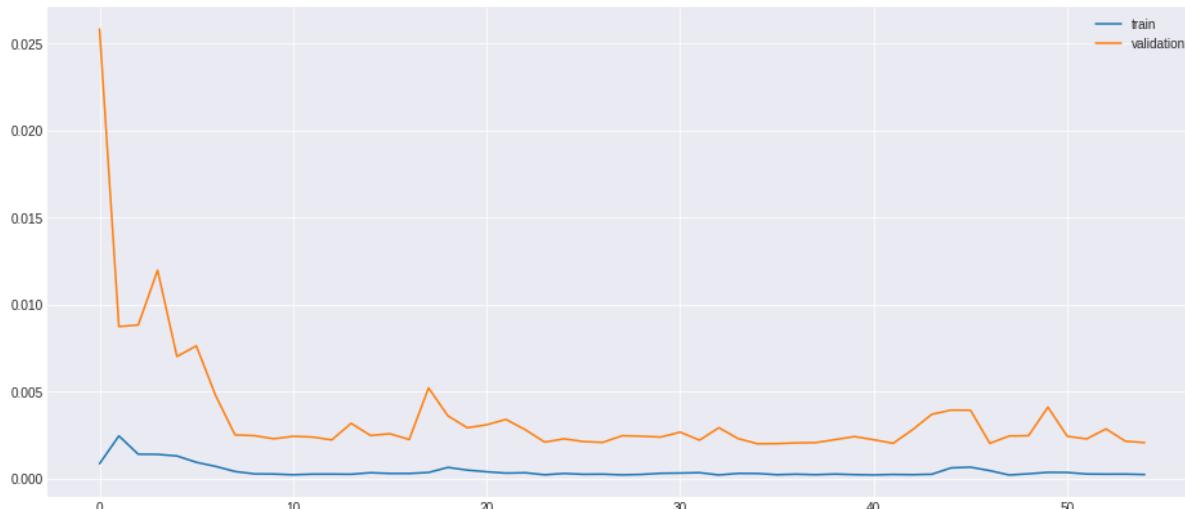
ارزیابی و بررسی عملکرد

در این بخش به ارزیابی نتایج حاصل از دو مدل طراحی شده و مدل ترکیبی می‌پردازیم.

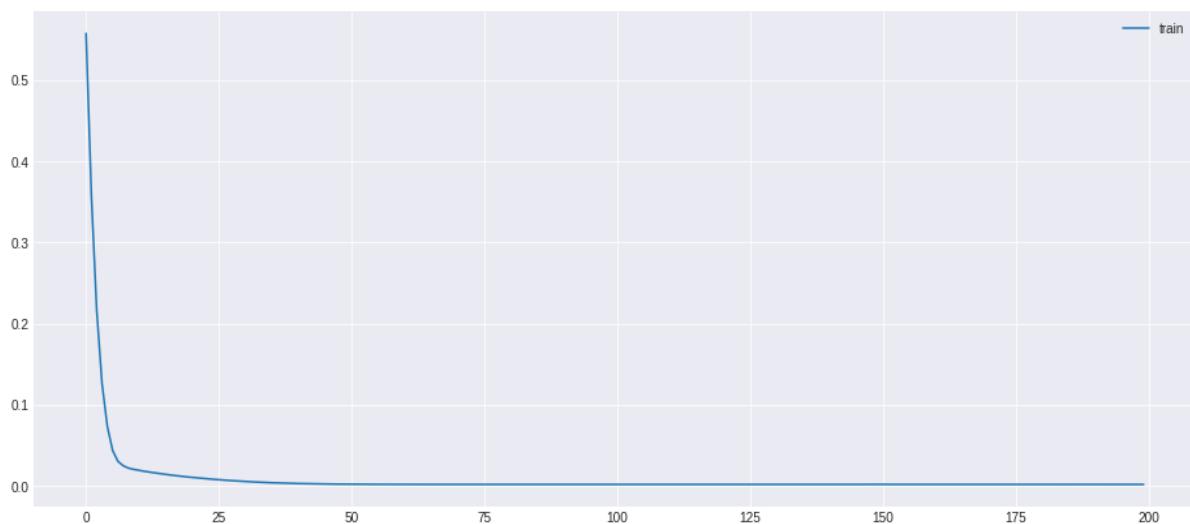
در زیر، نمودار خطای میانگین مربعات مدل‌ها را در فرآیند آموزش بر روی داده‌های رمزارز بیت‌کوین مشاهده می‌کنیم.



شکل ۳۷ - نمودار خطای مدل حافظه کوتاه مدت ماندگار در فرآیند آموزش



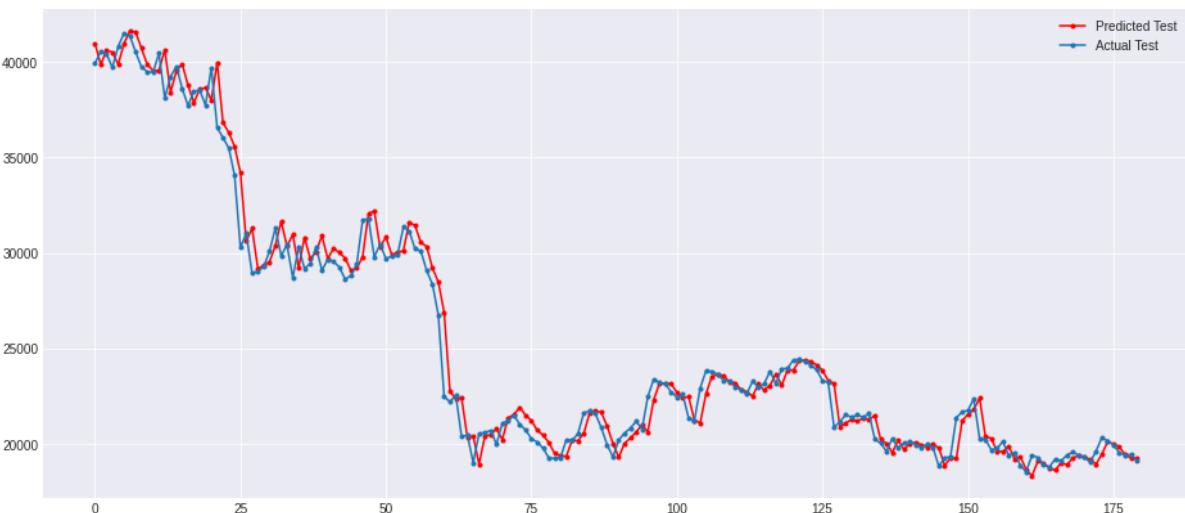
شکل ۳۸ - نمودار خطای مدل واحد بازگشتی دروازه‌ای در فرآیند آموزش



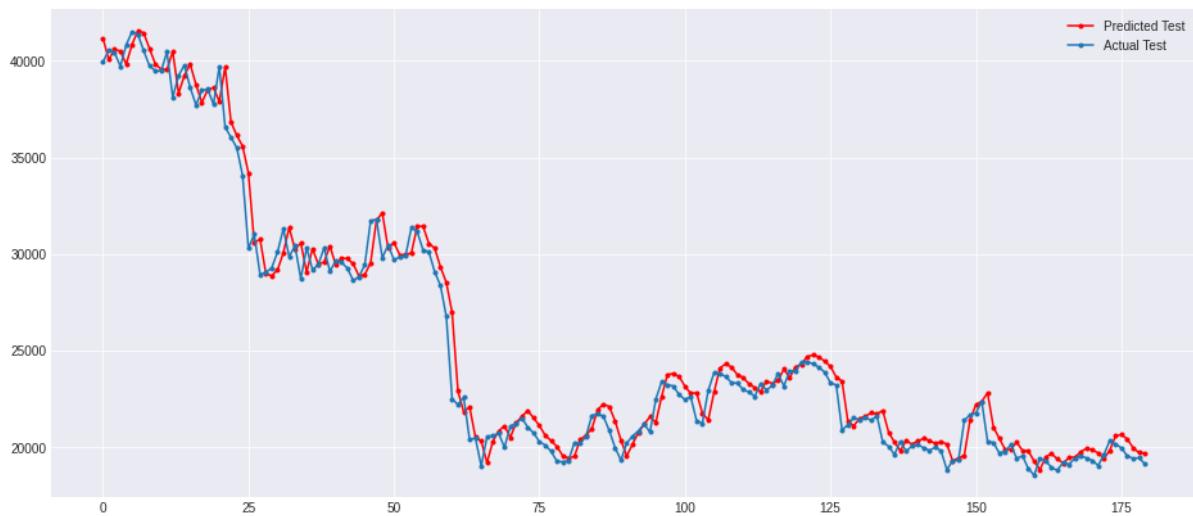
شکل ۳۹ - نمودار خطای مدل ترکیبی در فرآیند آموزش

همانطور که مشاهده می‌شود، در نمودار خطای مدل واحد بازگشتی در واژه‌ای به علت وجود لایه نوسانات بیشتری وجود دارد.

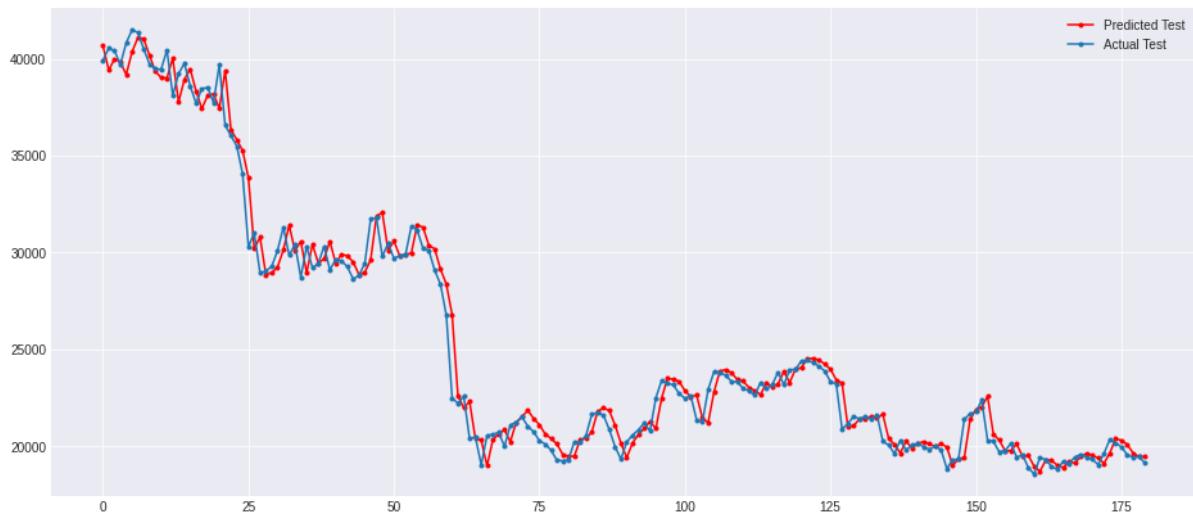
در ادامه نتایج پیش‌بینی مدل‌های نهایی خود را بر روی داده‌های آزمایش هر سه رمزارز نمایش داده شده است.



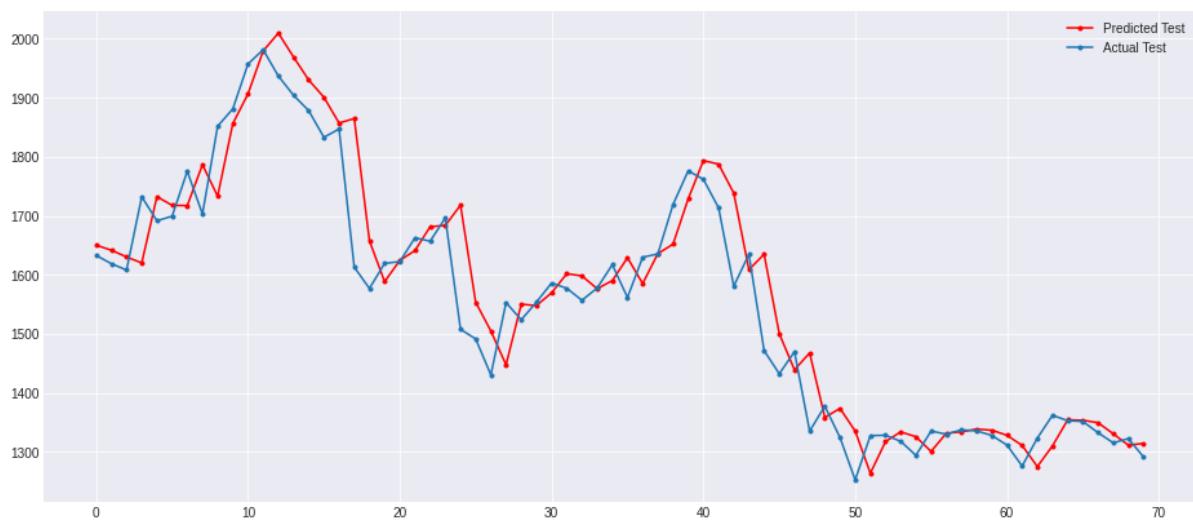
شکل ۴۰ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز بیت‌کوین توسط مدل حافظه کوتاه مدت ماندگار



شکل ۴۱ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمざرز بیت‌کوین توسط مدل واحد بازگشتی دروازه‌ای



شکل ۴۲ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزا رز بیت‌کوین توسط مدل ترکیبی



شکل ۴۳ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز اتریوم توسط مدل حافظه کوتاه مدت ماندگار



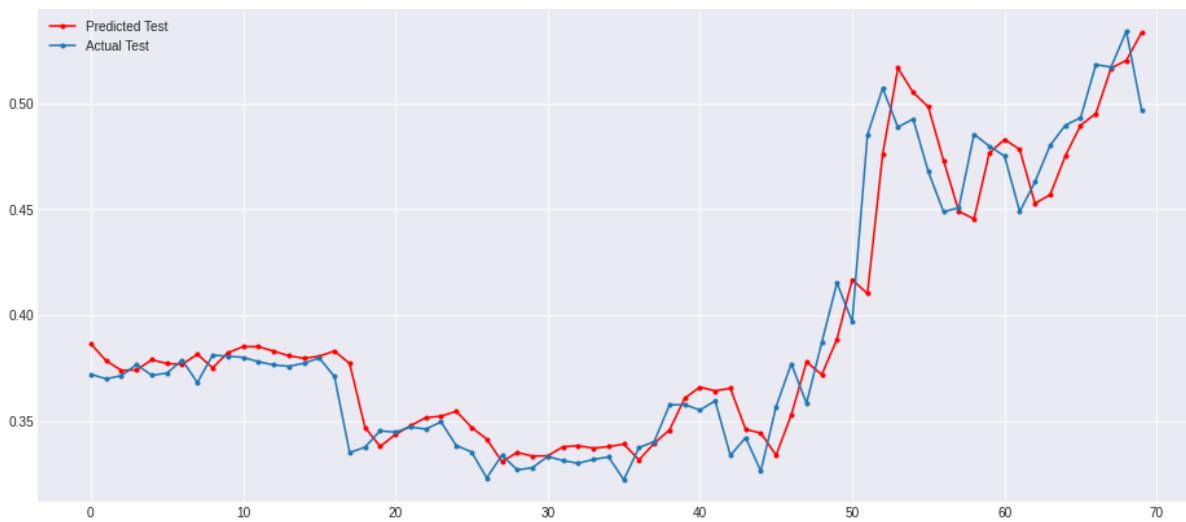
شکل ۴۴ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز اتریوم توسط مدل واحد بازگشتی دروازه‌ای



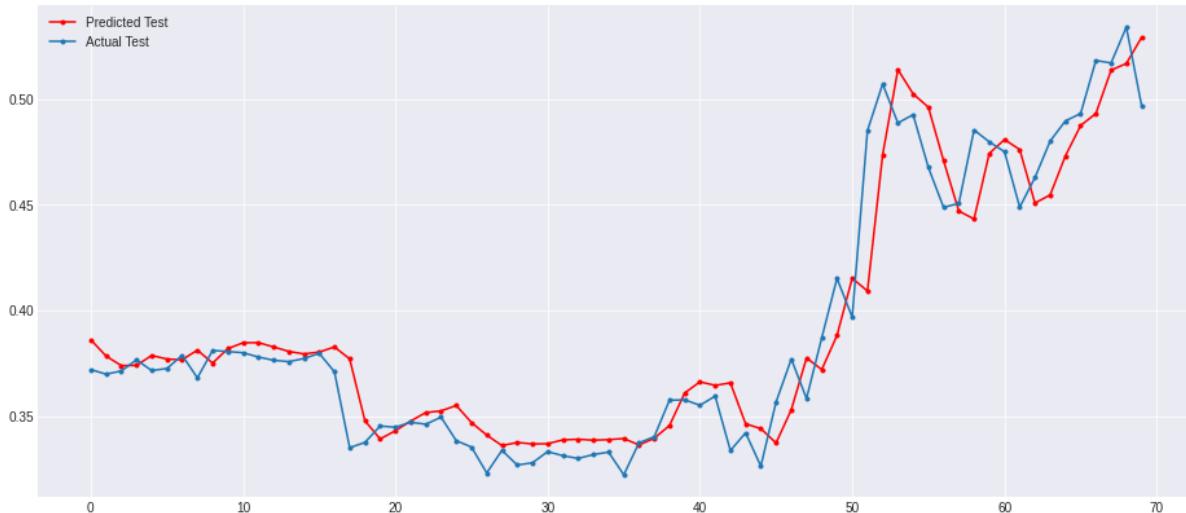
شکل ۴۵ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمざرز اتریوم توسط مدل ترکیبی



شکل ۴۶ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزا ریپل توسط مدل حافظه کوتاه مدت ماندگار



شکل ۴۷ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز ریپل توسط مدل واحد بازگشتی دروازه‌ای



شکل ۴۸ - نتایج حاصل از پیش‌بینی داده‌های آزمایش رمزارز ریپل توسط مدل ترکیبی

در جداول زیر خطای جذر میانگین مربعات حاصل از ۵ بار اجرای مدل‌ها و پیش‌بینی داده‌های هر سه رمزارز آورده شده است. در واقع این مقادیر، به صورت حدودی بیانگر مقدار میانگین اختلاف قیمت پیش‌بینی شده بر

فصل ۶: ارزیابی و بررسی عملکرد

اساس دلار می‌باشد. اما توضیح داده شد که با استفاده از معیار خطای جذر میانگین مربعات، وزن بیشتری به خطاهای بزرگ‌تر داده می‌شود.

جدول ۳ - خطای پیش‌بینی مدل‌های ارائه شده بر روی رمざرز بیت‌کوین

مدل LSTM	مدل GRU	مدل ترکیبی
۱۱۴۶	۹۸۴	۹۷۲
۱۱۲۵	۹۲۶	۹۳۵
۹۷۵	۹۳۲	۹۶۰
۱۰۵۴	۹۶۴	۹۸۰
۱۰۱۴	۱۰۰۳	۹۸۱

جدول ۴ - خطای پیش‌بینی مدل‌های ارائه شده بر روی رمزا‌رز اتریوم

مدل LSTM	مدل GRU	مدل ترکیبی
۶۶,۶	۶۵,۸	۶۵,۲
۶۵,۶	۶۷,۷	۶۵
۶۷,۶	۶۴,۹	۶۳,۶
۶۶,۶	۶۴,۹	۶۴,۳
۶۸,۲	۶۴,۴	۶۶,۸

جدول ۵ - خطای پیش‌بینی مدل‌های ارائه شده بر روی رمزا‌رز ریپل

مدل LSTM	مدل GRU	مدل ترکیبی

۰,۰۲۰	۰,۰۱۹	۰,۰۲۵
۰,۰۲۲	۰,۰۱۹	۰,۰۲۳
۰,۰۱۹	۰,۰۱۹	۰,۰۲۷
۰,۰۲۰	۰,۰۲۲	۰,۰۲۷
۰,۰۲۱	۰,۰۱۸	۰,۰۱۸

مشاهده می‌شود که عملکرد هر سه مدل بسیار نزدیک است. اما با توجه به نتایج، مدل واحد بازگشتی دروازه‌ای خطای کمتری نسبت به مدل حافظه کوتاه مدت ماندگار داشته است. نتایج مدل ترکیبی نیز نشان می‌دهد که میزان خطای این مدل در رمزارز بیت‌کوین تقریباً میان خطای دو مدل و در رمزارز اتریوم اغلب عملکردی بهتر و در رمزارز ریپل اغلب مقدار خطای بیشتری داشته است. نیاز به ذکر است که این تفاوت عملکرد مدل‌ها در رمزارزهای مختلف به غیر از تاثیر نوسانات و الگوهای آن ارز به‌طورکلی، به نوسانات و تغییرات روند در بازه داده‌های ارزیابی و آزمایش نیز بستگی دارد.

فصل ٧

جمع بندی

۱-۷- مقدمه

در این پژوهه، با بررسی روش‌های پیش‌بینی رمざرزها با استفاده از شبکه‌های عمیق، شبکه‌های بازگشتی را به علت عملکرد خوبشان در پیش‌بینی داده‌های زمانی، انتخاب کردیم. در آخر از دو مدل پرطوفدار حافظه کوتاه مدت ماندگار و واحد بازگشتی دروازه‌ای استفاده کردیم. پس از یافتن فرآپارامترهای مناسب و ارزیابی مدل‌ها، با استفاده از روش‌های تجمعی و به هدف ایجاد یک مدل قابل اعتمادتر و با واریانس کمتر، این دو مدل را ترکیب نمودیم و مدل جدیدی ارائه دادیم.

۲-۷- نتایج

با توجه به ارزیابی‌های انجام شده، دیدیم که هر دو مدل عملکرد نزدیکی داشتند. مدل ترکیبی ارائه شده نیز در بعضی از شرایط، خطای کمتر و نتایج قابل اعتمادتری ارائه داد، اما در نوسانات شدید عملکرد ضعیفتری داشت. از این رو، ما امکان استفاده از هر سه مدل را در سامانه پیش‌بینی خود فراهم نمودیم.

نتیجه‌گیری که از این پژوهه می‌توان داشت، این است که تحلیل و پیش‌بینی بازار، بخصوص بازار رمزارزها به علت نوسانات شدید، امری پیچیده و دشوار است. با اینکه مدل‌های ما مثدار خطای زیادی نداشتند، اما با بررسی نتایج متوجه تاخیر آن‌ها در تشخیص روندها می‌شویم. بنابراین، نتایج این مدل‌ها در بازارهای پر نوسانی مانند بازار رمزارزها، قابل اعتماد نیست و در عمل نمی‌توان آن‌ها را بهنهایی مبنای معامله خود قرار داد.

۳-۷- کارهای آینده

همانطور که در فصل دوم توضیح داده شد، روش‌های مختلفی برای تحلیل بازار وجود دارد. استفاده از شبکه‌های بازگشتی تنها یک روش در حوزه یادگیری ماشین بود. در کارهای آینده سعی می‌کنیم از روش‌ها و شاخص‌های تکنیکی در کنار مدل خود استفاده کنیم. شاخص‌های حجم و نوسان‌گر بخصوص در پیش‌بینی تغییرات روند می‌توانند به ما کمک کنند.

در این پژوهه ما تنها از قیمت پایانی استفاده کردیم. در کارهای آینده، قیمت باز شدن و قیمت بالا و پایین را نیز جهت افزایش دقت، در کار خود دخیل خواهیم کرد. بررسی این شمع‌های قیمتی در پیش‌بینی تغییرات روند نیز به ما کمک می‌کنند. همچنانی از تحلیل بنیادین، بخصوص تحلیل اخبار، جهت پیش‌بینی نوسانات شدید، استفاده خواهیم کرد.

منابع

1. Abouloula K, Habil BE, Krit SD. Money management limits to trade by robot trader for automatic trading. International Journal of Engineering, Science and Mathematics. 2018 Mar;7(3):195-206.
2. Murphy JJ. Technical analysis of the financial markets: A comprehensive guide to trading methods and applications. Penguin; 1999.
3. Nielsen MA. Neural networks and deep learning. San Francisco, CA, USA: Determination press; 2015 Sep 25.
4. Nikou M, Mansourfar G, Bagherzadeh J. Stock price prediction using DEEP learning algorithm and its comparison with machine learning algorithms. Intelligent Systems in Accounting, Finance and Management. 2019 Oct;26(4):164-74.
5. Fazeli A, Houghten S. Deep learning for the prediction of stock market trends. In2019 IEEE International Conference on Big Data (Big Data) 2019 Dec 9 (pp. 5513-5521). IEEE.
6. Naik N, Mohan BR. Study of stock return predictions using recurrent neural networks with LSTM. InInternational conference on engineering applications of neural networks 2019 May 24 (pp. 453-459). Springer, Cham.
7. Xu Y, Keselj V. Stock prediction using deep learning and sentiment analysis. In2019 IEEE international conference on big data (big data) 2019 Dec 9 (pp. 5573-5580). IEEE.
8. Hossain MA, Karim R, Thulasiram R, Bruce ND, Wang Y. Hybrid deep learning model for stock price prediction. In2018 ieee symposium series on computational intelligence (ssci) 2018 Nov 18 (pp. 1837-1844). IEEE.
9. Qian F, Chen X. Stock prediction based on LSTM under different stability. In2019

-
-
- IEEE 4th International Conference on Cloud Computing and Big Data Analysis (ICCCBDA) 2019 Apr 12 (pp. 483-486). IEEE.
- 10. Lakshminarayanan SK, McCrae JP. A Comparative Study of SVM and LSTM Deep Learning Algorithms for Stock Market Prediction. InAICS 2019 Dec (pp. 446-457).
 - 11. Rana M, Uddin MM, Hoque MM. Effects of activation functions and optimizers on stock price prediction using LSTM recurrent networks. InProceedings of the 2019 3rd International Conference on Computer Science and Artificial Intelligence 2019 Dec 6 (pp. 354-358).
 - 12. Liu Y, Wang Z, Zheng B. Application of regularized GRU-LSTM model in stock price prediction. In2019 IEEE 5th International Conference on Computer and Communications (ICCC) 2019 Dec 6 (pp. 1886-1890). IEEE.